תחום ההתמחות של מפתחי GitHub מתוך רשת מעקב הדדית

פרויקט גמר — אלגוריתמים ברשתות

נועה ירין לוי (208101196) · ג'ימי חלאוי (208301176) · אופיר אטיאס (211446935)

מרצה: ד"ר אבנר פריאל

תקציר

העבודה מנתחת רשת לא־מכוונת של 37,700 מפתחי GitHub ו־289,003 קשרי מעקב הדדיים. נבדקו סיווג תחום מקצועי ממבנה הרשת, הערך המשלים של תוכן, שחזור מדויק של קשתות שהוסתרו ומובהקות מבנית מול מודלי אפס. כל ניסויי החיזוי חזרו בחמש חלוקות קבועות, ללא שימוש בתוויות הבדיקה לבניית מאפיינים או לכיול. שיעור הקשתות התוך־תחומיות הוא 84.5%; המסווג הידני הטוב הגיע ל־ROC-AUC 0.869; DeepWalk ו־Node2Vec הגיעו ל־0.891 ו־0.890. בשחזור קשתות הובילה Preferential Attachment עם ROC-AUC 0.924. אלו קשרים חיזויים בתנאי הניסוי ואינם ראיה לסיבתיות.

שאלות המחקר

RQ1: באיזו מידה שכנות, מרכזיות, קהילות וייצוגי הליכות מאפשרים לסווג את תחום המפתח כאשר תוויות הבדיקה מוסתרות?

RQ2: מהו הערך השולי של מבנה הרשת מול מאפייני תוכן, ומה מוסיף השילוב?

RQ3: האם ניתן לשחזר קשתות שהוסתרו אקראית תוך שמירת קישוריות, והאם same-field קל יותר לשחזור מ־cross-field?

RQ4: האם הומופיליה ומודולריות חריגות מול מודלי אפס, ואילו מאפיינים משחזרים ER, BA, Small-World ורשת משמרת־דרגה?

רכיבי קישוריות	צפיפות	דרגה ממוצעת	קשתות	צמתים
1	0.000407	15.332	289,003	37,700

מסגרת מתודולוגית ושיטות

בסיווג הצמתים מבנה הגרף גלוי (transductive), אך תוויות test מוסתרות. מאפייני שכנים וקהילה מחושבים מתוויות train בלבד. בכל seed בוצעה חלוקה מרובדת 70/30, וסף ההחלטה כויל רק על validation פנימי מתוך train.

ניתוח הרשת כולל Degree, Clustering, PageRank, Betweenness בקירוב, HITS Hub יחיד, Louvain ומודולריות. התפלגות הדרגות נבחנת בזהירות מול חלופות. לשחזור קשתות מוגן עץ פורש; non-edges מותאמים לפי ML-ML, Web-Web ו־Web-ML.

קלט מרכזי	מודל	משפחה
שכיחות train	Majority	בסיס
תוויות שכני train	Neighbor Majority	בסיס
מרכזיות ומבנה	LogReg Graph	ידני
מבנה וקהילה	LogReg Graph + Community	ידני
מאפייני MUSAE	LogReg Content	תוכן
רשת ותוכן	LogReg Hybrid	היברידי
הליכות אחידות	LogReg DeepWalk	הטמעה
הטמעה ומבנה	DeepWalk + ידני	הטמעה
הליכות מוטות	LogReg Node2Vec	הטמעה
הטמעה ומבנה	Node2Vec + ידני	הטמעה

שחזור קשתות ומודלי אפס

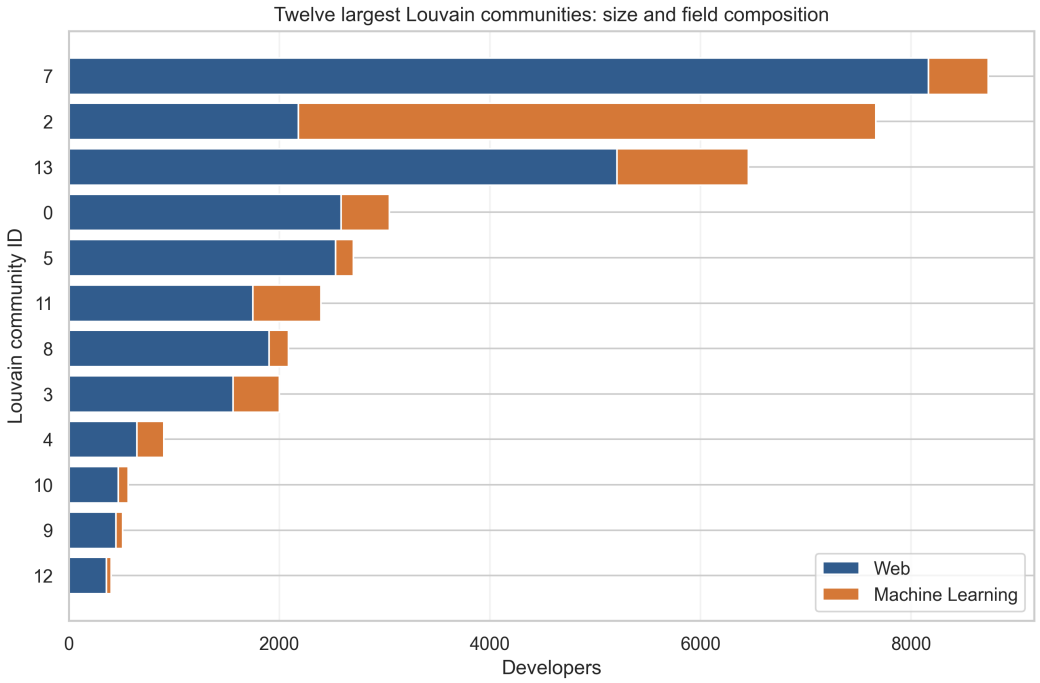
השיטות הן Same Community, DeepWalk, Preferential Attachment, Adamic-Adar, Jaccard, Common Neighbors ו־Node2Vec. ההטמעות והקהילות נלמדות מחדש על גרף האימון בלבד. ערכי p אמפיריים מחושבים כ־(B+1)/(b+1), ולכן אינם אפס. ההשוואות כוללות 1,000 ערבובי תוויות, 20 חיווטים משמרי־דרגה ומודלי ER, BA ו־Watts-Strogatz.

מבנה הרשת, מרכזיות וקהילות

הרשת קשירה וצפופה מעט בלבד (0.000407). מדדי Degree ו־PageRank מדגישים מוקדי קשרים, בעוד Betweenness מדגיש תיווך בין אזורים; לכן רשימות המובילים אינן זהות.

ציון	דרגה	Node ID	מפתח מוביל	מדד
0.250882	9458	31890	dalinhuang99	Degree
0.016514	9458	31890	dalinhuang99	PageRank
0.270590	7085	27803	nfultz	Betweenness

חפיפת Jaccard בין 20 המובילים ב־Degree וב־PageRank היא 1.000, לעומת 0.600 בין Degree ל־Betweenness. הפער ממחיש שמתווכים אינם בהכרח בעלי מספר הקשרים הגדול ביותר.

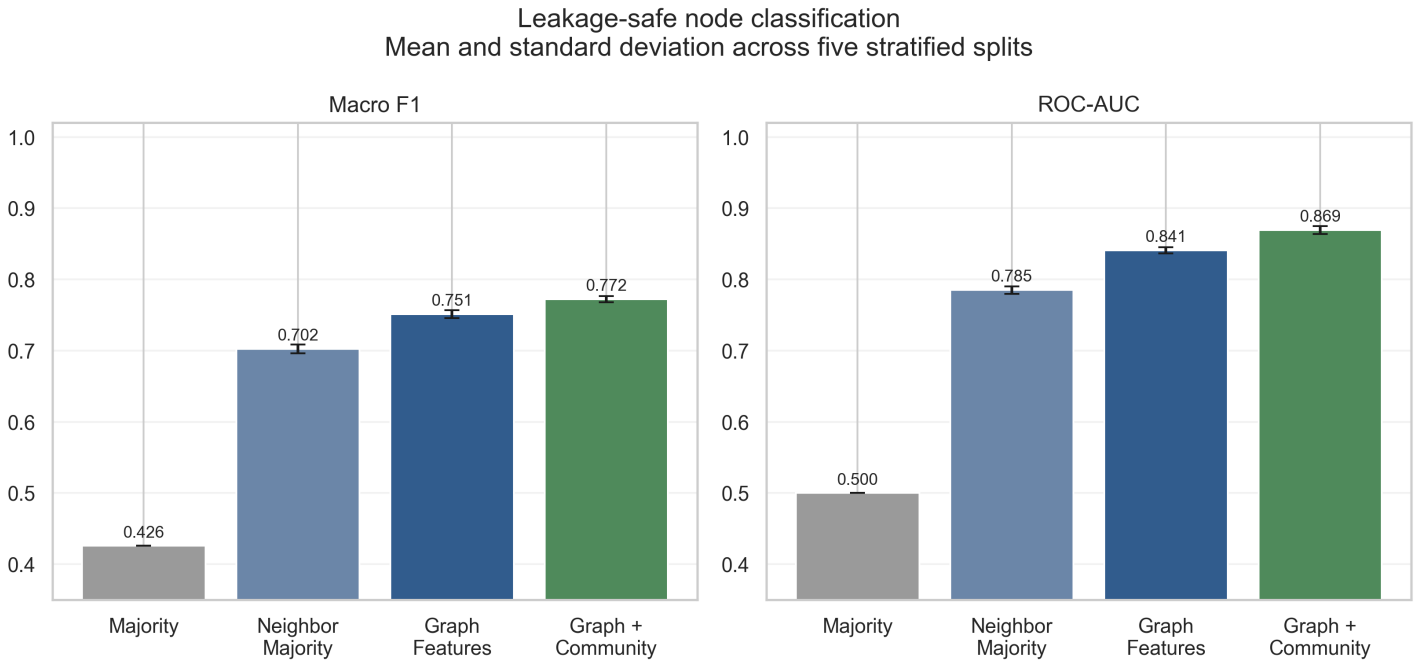


איור 1. קהילות Louvain הגדולות: גודל והרכב תחומי.

Louvain מצא 31 קהילות עם מודולריות 0.453; הקהילה הגדולה מכילה 8,732 צמתים והטוהר המשוקלל הוא 0.830. קהילות מעורבות מונעות פירוש דטרמיניסטי של השתייכות קהילתית.

RQ1 — סיווג צמתים

מודל	Macro F1	SD	ROC-AUC	SD
Majority Baseline	0.426	0.000	0.500	0.000
Neighbor Majority	0.702	0.006	0.785	0.005
LogReg Graph Features Only	0.751	0.005	0.841	0.004
LogReg Graph + Community Features	0.772	0.004	0.869	0.005



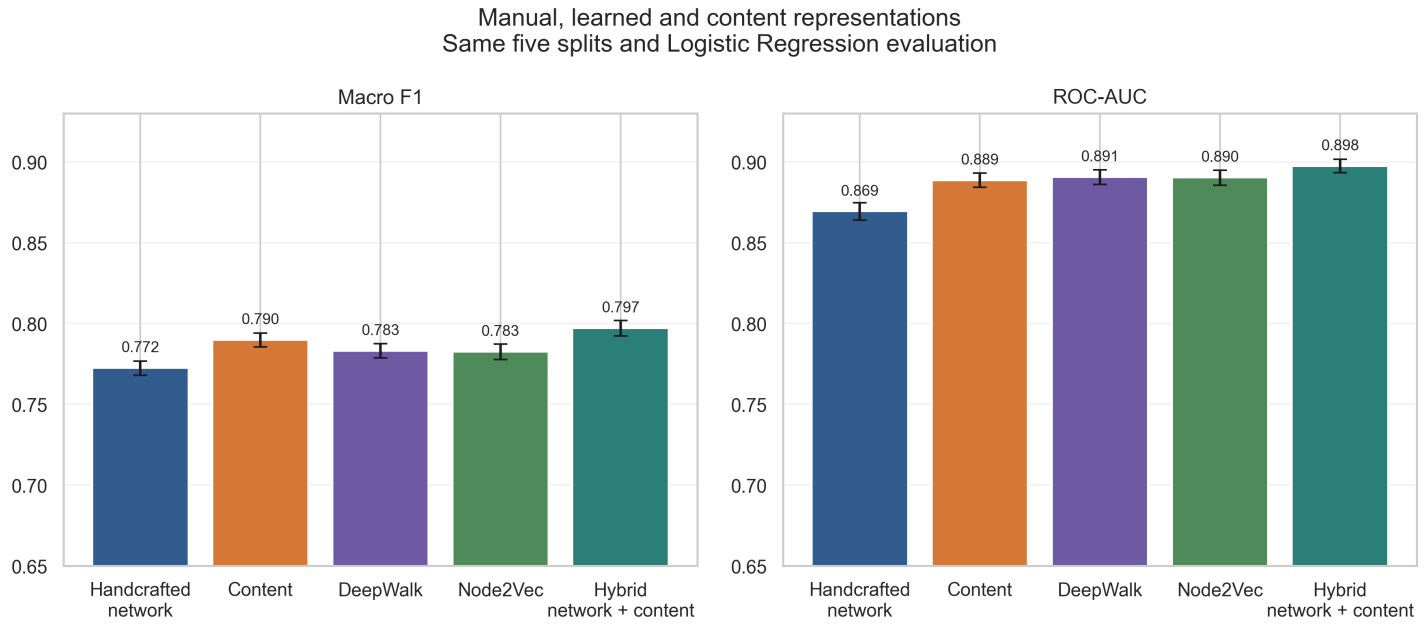
איור 2. סיווג צמתים בחמש חלוקות; פסי השגיאה הם סטיית תקן.

הוספת קהילה העלתה את ROC-AUC ל־0.869. הסף שנבחר על validation בלבד היה 0.550 בממוצע. Precision השתנה מ־0.622 ל־0.646, ו־Recall מ־0.721 ל־0.696; זהו trade-off תפעולי ולא שיפור בכל מדד.

מסקנת RQ1: מבנה הרשת מספק אות חיזויי מעל קווי הבסיס, וקהילה מוסיפה מידע מעבר לשכנות ולמרכזיות. המסקנה מוגבלת לפרוטוקול transductive ולתווית הבינארית שנבדקה.

RQ2 — רשת, תוכן וייצוגים נלמדים

ייצוג / מקור מידע	Macro F1	ROC-AUC	SD AUC
LogReg Content Features Only	0.790	0.889	0.004
(LogReg Hybrid (Network + Content	0.797	0.898	0.004
(LogReg Network Only (Graph + Community	0.772	0.869	0.005
LogReg Node2Vec	0.783	0.890	0.005
LogReg DeepWalk	0.783	0.891	0.004
LogReg Node2Vec + Graph + Community	0.791	0.899	0.005
LogReg DeepWalk + Graph + Community	0.791	0.900	0.005



איור 3. פיצ'רים ידניים, תוכן, DeepWalk, Node2Vec ושילובים.

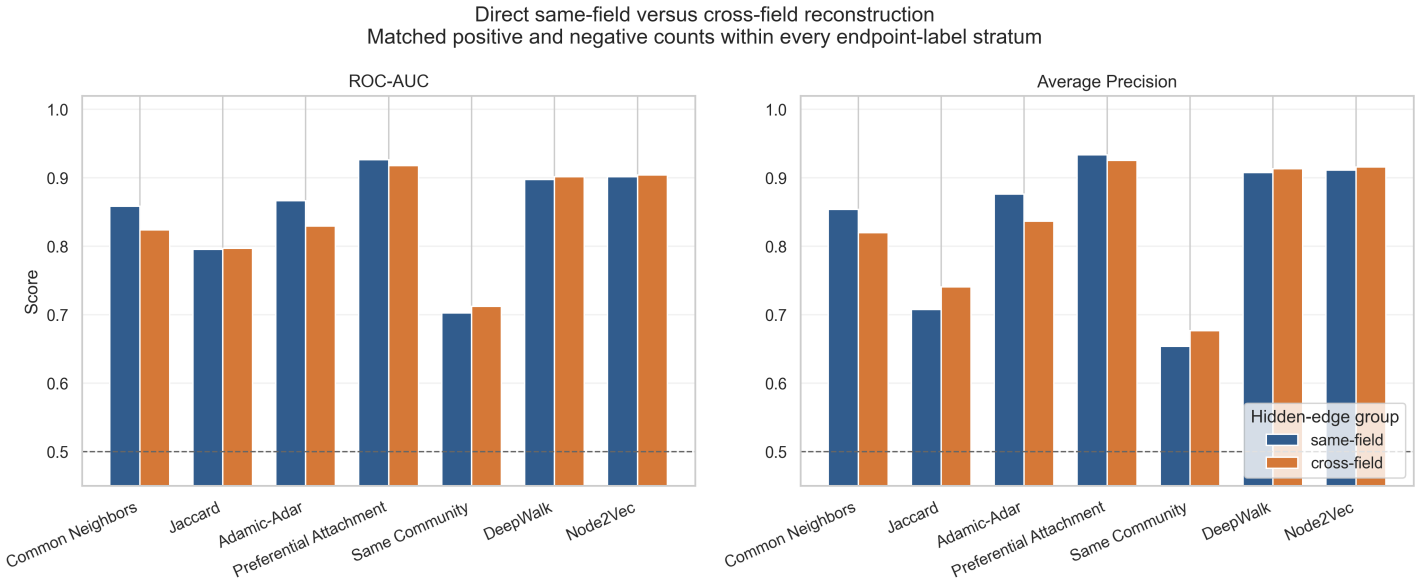
תוכן לבדו הגיע ל־0.889 AUC, מול 0.869 ברשת ידנית ו־0.898 בשילוב. DeepWalk ו־Node2Vec לבדם הגיעו ל־0.891 ו־0.890. הדמיון אינו מוכיח שקילות בין מקורות מידע.

מסקנת RQ2: התוכן חזק מן הייצוג הידני של הרשת, אך השילוב מוסיף ביצועים; הטמעות הליכות מרכזות מידע מבני שימושי ומצמצמות חלק מן הפער.

RQ3 — שחזור קשתות קשיר

בכל seed הוגנו קשתות עץ פורש, והוסרו 10% רק מן הקשתות האחרות. בכל חמש החלוקות גרף האימון נשאר רכיב קשיר יחיד וללא צמתים מבודדים. לכל positive הותאם non-edge מאותו סוג קצוות; Louvain וההטמעות חושבו על train בלבד.

שיטה	ROC-AUC	SD	Average Precision	SD
Preferential Attachment	0.924	0.001	0.931	0.001
Node2Vec	0.900	0.003	0.911	0.002
DeepWalk	0.897	0.003	0.907	0.002
Adamic-Adar	0.860	0.003	0.870	0.002
Common Neighbors	0.853	0.003	0.848	0.003
Jaccard	0.796	0.004	0.713	0.006
Same Community	0.704	0.004	0.657	0.004

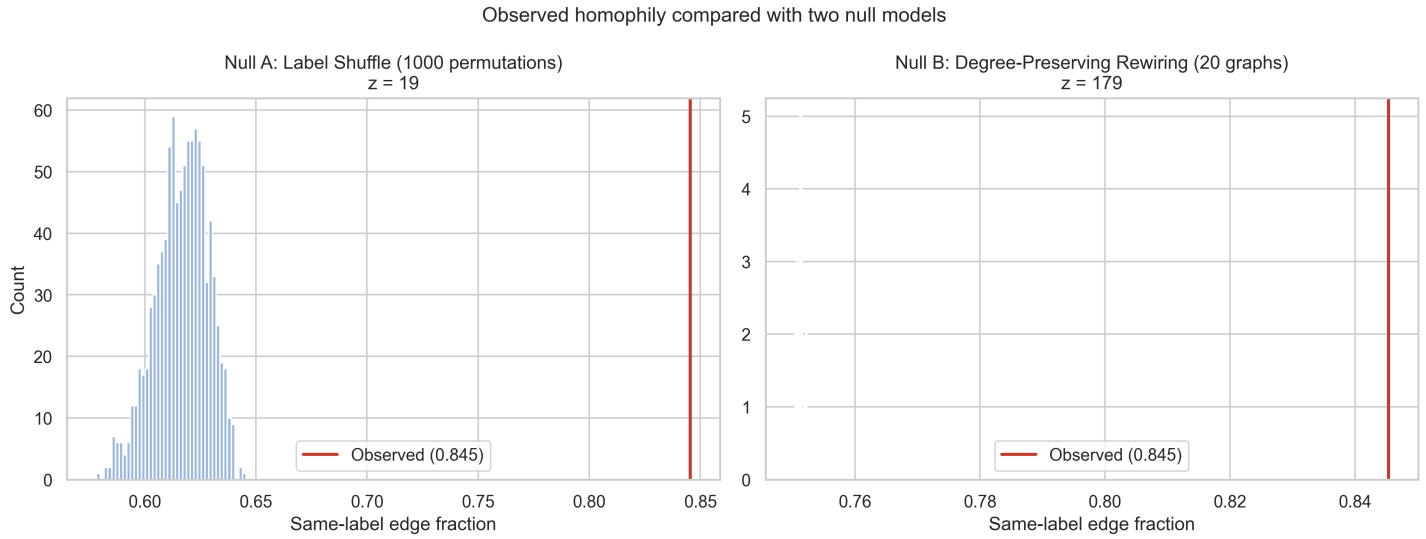


איור 4. השוואה ישירה same-field מול cross-field בדגימה מאוזנת.

Preferential Attachment הוביל עם AUC 0.924. עבורו same-field קיבל AUC 0.926 ו־AP 0.933, לעומת AUC 0.918 ו־AP 0.925 ב־cross-field. הפערים בכל השיטות קטנים ותלויי שיטה; הממצא מתאר שחזור קשתות שהוסתרו, לא התפתחות קשרים בזמן.

RQ4 — מודלי אפס ומודלי רשת

מודל אפס	נצפה	ממוצע אפס	SD	p אמפירי
ערבוב תוויות	0.845	0.617	0.012	0.000999
חיווט משמר־דרגה	0.845	0.751	0.001	0.047619



איור 5. הומופיליה נצפית מול ערבוב תוויות וחיווטים משמרי־דרגה.

רשת	קשתות	Clustering	מרחק ממוצע	דרגת שיא
GitHub observed	289,003	0.1675	3.218	9458
Erdos-Renyi	289,003	0.0004	4.125	34
(Barabasi-Albert (m=8	301,536	0.0034	3.590	891
(Watts-Strogatz (k=16, p=0.1	301,600	0.5117	5.552	22
Degree-preserving configuration null	289,003	0.0914	3.156	9458

המודולריות הנצפית היא 0.453, מול 0.189 בחיווטים משמרי־דרגה (p=0.047619). התאמת Power Law נתנה α=2.54; ההשוואה ללוג־נורמלית אינה מצדיקה הכרזה גורפת על scale-free. ER אינו משחזר התקבצות או דרגת שיא; BA משחזר חלק מן הזנב; Small-World משחזר התקבצות ומרחקים קצרים.

דיון מסכם ומגבלות

התמונה המצטברת עקבית: קיים קשר תיאורי חזק בין מבנה הרשת לתחום; קהילות והטמעות מוסיפות כוח חיזויי; תוכן מספק אות משלים. מודלי האפס מראים שרצף הדרגות מסביר חלק מן ההומופיליה אך לא את כולה. הצלחת Preferential Attachment תואמת את חשיבות הדרגות, אך אינה מזהה מנגנון סיבתי.

מגבלות

- הנתונים הם תמונת מצב מיוני 2019 ואינם מייצגים בהכרח את GitHub כיום.
- תווית היעד בינארית ונגזרה ממידע פרופיל; ייתכנו רעש וחסר.
- הסיווג transductive ואינו מדמה צומת חדש ללא קשרים ידועים.
- Betweenness מחושב בקירוב וההטמעות נבדקו בתקציב קבוע ללא חיפוש רחב.
- שחזור קשתות שהוסתרו אינו תחזית זמן ואינו מזהה סיבתיות או כיווניות.
- מודלי האפס והמודלים הגנרטיביים מבודדים מאפיינים ואינם תהליך מלא.

מסקנות

RQ1: מבנה הרשת מאפשר סיווג מעל קווי הבסיס. RQ2: יש חפיפה חלקית ומידע משלים בין רשת לתוכן. RQ3: שחזור קשתות אפשרי תוך שמירת קישוריות, והפער same/cross תלוי בשיטה. RQ4: ההומופיליה והמודולריות חריגות ביחס למודלי האפס שנבדקו. הממצאים תומכים בערך האנליטי של רשתות מקצועיות, תוך שמירה על ניסוח תיאורי וזהיר.

מקורות

1. Rozemberczki, Allen & Sarkar (2019), MUSAE.
2. Blondel et al. (2008), Fast unfolding of communities.
3. Perozzi, Al-Rfou & Skiena (2014), DeepWalk.
4. Grover & Leskovec (2016), node2vec.
5. Liben-Nowell & Kleinberg (2003), Link Prediction.
6. Clauset, Shalizi & Newman (2009), Power-law distributions.
7. Page et al. (1999), PageRank.
8. מצגות ותרגולי הקורס: מרכזיות, קהילות, מודלי רשת, שחזור והטמעות.