דו"ח מסכם בקורס אלגוריתמים ברשתות

חיזוי תחום התמחות של מפתחי GitHub לפי קשרי מעקב הדדיים ברשת

נועה ירין לוי ג'ימי חלאוי אופיר אטיאס

208101196 208301176 211446935

מרצה: ד"ר אבנר פריאל



תקציר

עבודה זו בוחנת האם ניתן לחזות את תחום ההתמחות (Web מול Machine Learning) של מפתחי GitHub מתוך מבנה רשת קשרי המעקב ההדדיים בלבד, כאשר מאפייני תוכן משמשים כנקודת ייחוס. סביב משימה זו נבחנות ארבע שאלות מחקר: כוחו החיזויי של המבנה, ערכו ביחס לתוכן, יכולת חיזוי הקשרים עצמם, ומובהקות התכונות המבניות מול מודלי רשת אקראיים. נבדק סולם של אחד-עשר מודלים, מקו בסיס ועד DeepWalk ו-GCN, תחת פרוטוקול אחיד של חמש חלוקות ומבחני מובהקות זוגיים. הממצאים: כל שלב בסולם משפר את קודמו בכל אחת מחמש החלוקות, ייצוג DeepWalk של הרשת לבדה שקול בפועל למאפייני התוכן (0.887 AUC מול 0.889, הפרש הקטן מסטיית התקן שבין החלוקות), ארבעה מודלים שונים מתכנסים לתקרה משותפת (AUC≈0.90) הרומזת לרעש תוויות, קשרי המעקב ניתנים לחיזוי (0.910 AUC) כשצפיפות שכונתית ולא דמיון תחומי היא הגורם המסביר, וההומופיליה (84.5%) עומדת גם מול מודל אפס משמר-דרגות, אם כי כ-60% ממנה מוסברים בהבדלי דרגות.

מבוא, מוטיבציה והגדרת הבעיה

פלטפורמת GitHub הפכה בשנים האחרונות להרבה יותר ממאגר ציבורי לאחסון קוד והיא מתפקדת כרשת חברתית ומקצועית גדולה ופעילה. בסביבה זו מפתחים עוקבים זה אחר זה, משתפים פעולה בפרויקטים ויוצרים קשרים המשקפים לעיתים קרובות תחומי עניין מקצועיים משותפים. בשל כך ניתן לייצג את המערכת הזו באופן טבעי באמצעות גרף שבו כל צומת מייצג מפתח וכל קשת מייצגת קשר מעקב הדדי בין שני מפתחים. הנחת המוצא של עבודה זו היא שקשרים אלו אינם נוצרים באקראי. למעשה קשרים אלו מבוססים על תופעת ההומופיליה, הנטייה הטבעית של אנשים בעלי תחומי עניין ומאפיינים דומים ליצור קשרים ולהתחבר אחד לשני והנחה זו עצמה נבחנת בעבודה באופן כמותי.

מטרת הפרויקט היא לבחון את הקשר בין מבנה הרשת לבין התחום המקצועי של המפתחים, על פני **ארבע שאלות מחקר**:

שאלה 1- חיזוי צמתים: באיזו מידה מאפיינים מבניים של הרשת - שכנות, מרכזיות, קהילות וייצוגים נלמדים (DeepWalk, GCN) מאפשרים לחזות האם מפתח משתייך לתחום Web או Machine Learning?

שאלה 2- רשת מול תוכן: מהו הערך השולי של מבנה הרשת ביחס למאפייני תוכן (repositories מסומני כוכב, מעסיק, מיקום)? האם ייצוג מבני חזק יכול להחליף מידע תוכני?

שאלה 3- חיזוי קשתות: האם ניתן לחזות את היווצרות קשרי המעקב עצמם באמצעות היוריסטיקות מבניות, והאם קשרים בתוך אותו תחום צפויים יותר מקשרים חוצי-תחום?

שאלה 4- תוקף מבני: האם התכונות המבניות שעליהן נשענת העבודה - הומופיליה, מבנה קהילתי והתפלגות דרגות כבדת-זנב מובהקות סטטיסטית ביחס למודלי רשת אקראיים, או שהן ניתנות להסבר על ידי מבנה הדרגות בלבד?

- אם התשובות חיוביות, המשמעות היא שקשרי המעקב ההדדיים אינם אקראיים ביחס לתחום המקצועי, אלא מכילים מידע מבני עשיר שניתן לנצל באמצעות אלגוריתמים בגרפים, החל מהיוריסטיקות שכנות פשוטות ועד למידת ייצוגים ורשתות נוירונים גרפיות.

עבודה קשורה

מאגר הנתונים של MUSAE: Rozemberczki, Allen & Sarkar (2019) אספו את הדאטה מה-API הציבורי של GitHub ופיתחו את שיטת MUSAE- ייצוגי צמתים המשלבים את מבנה הרשת עם מאפייני תוכן. אנו לוקחים כיוון שונה: צנרת החיזוי שלנו היא Network-Only, ומאפייני התוכן משמשים רק כנקודת ייחוס בניסוי Ablation המכמת את ערכו של כל מקור מידע בנפרד.

הומופיליה ברשתות חברתיות: McPherson et al. (2001, "Birds of a Feather") הראו שדמיון במאפיינים הוא המנבא החזק ביותר להיווצרות קשרים חברתיים. אנו מכמתים את התופעה באמצעות מודלי אפס: איזה חלק מההומופיליה ברשת GitHub אמיתי, ואיזה מוסבר על ידי מבנה הדרגות בלבד.

זיהוי קהילות באמצעות Louvain: Blondel et al. (2008) הציגו גישה חמדנית ויעילה למציאת קהילות ברשתות גדולות באמצעות מקסום איטרטיבי של המודולריות. בעבודתנו האלגוריתם מזהה את הקהילות הטבעיות ברשת המפתחים, ומהן נגזרים מדד הטוהר (Purity) ותכונות הקהילה המשמשות כפיצ'רים במודל הלוגיסטי.

למידת ייצוגי צמתים DeepWalk: Perozzi et al. (2014) הציגו שיטה הלומדת וקטור ייצוג לכל צומת: הילוכים אקראיים על הגרף מוזנים כ"משפטים" למודל Word2Vec, כך שקרבה ברשת מתורגמת לקרבה וקטורית ללא הנדסת פיצ'רים. בעבודתנו DeepWalk בוחן האם ייצוג נלמד עולה על מאפיינים ידניים.

רשתות נוירונים גרפיות GCN: Kipf & Welling (2017) הציגו את ה-Graph Convolutional Network, שבו כל שכבה מעדכנת את ייצוג הצומת באמצעות מיצוע ממושקל של ייצוגי שכניו (Message Passing) על גבי מטריצת שכנות מנורמלת. זהו הייצוג המודרני של סיווג צמתים semi-supervised, ואנו בוחנים אותו כקצה העליון של סולם המודלים, עם שתי גרסאות קלט שונות המבודדות את תרומת הארכיטקטורה מתרומת הייצוג.

חיזוי קשרים: Liben-Nowell & Kleinberg (2003) הגדירו את בעיית ה-Link Prediction ברשתות חברתיות והציגו את ההיוריסטיקות הקלאסיות שבהן אנו משתמשים Common Neighbors, Adamic-Adar ו-Preferential Attachment.

אנו מרחיבים את הניתוח בריבוד התוצאות לפי תוויות הקצוות (Web-Web, ML-ML, Web-ML), המחבר בין בעיית חיזוי הקשרים לתופעת ההומופיליה.

התפלגויות חוק חזקה ומודלי רשת: Clauset, Shalizi & Newman (2009) הציגו את המתודולוגיה הסטטיסטית המקובלת להתאמת חוק חזקה לנתונים אמפיריים, ו-Broido & Clauset (2019, "Scale-free networks are rare") הראו שברוב הרשתות האמיתיות לא ניתן להבחין בין חוק חזקה להתפלגויות כבדות-זנב אחרות. אנו מיישמים את המתודולוגיה הזו על התפלגות הדרגות של רשת המפתחים ומאמצים את הניסוח הזהיר שהספרות העדכנית ממליצה עליו.

תיאור מסד הנתונים

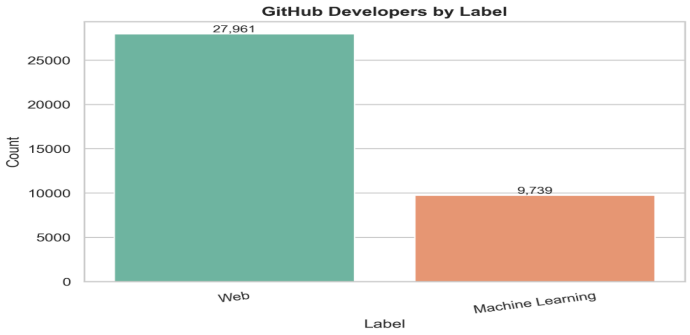
הנתונים נלקחו מ-MUSAE GitHub Social Network. זהו גרף לא-מכוון של מפתחי GitHub שנאסף מה-API הציבורי ביוני 2019.

מדדים מרכזיים:

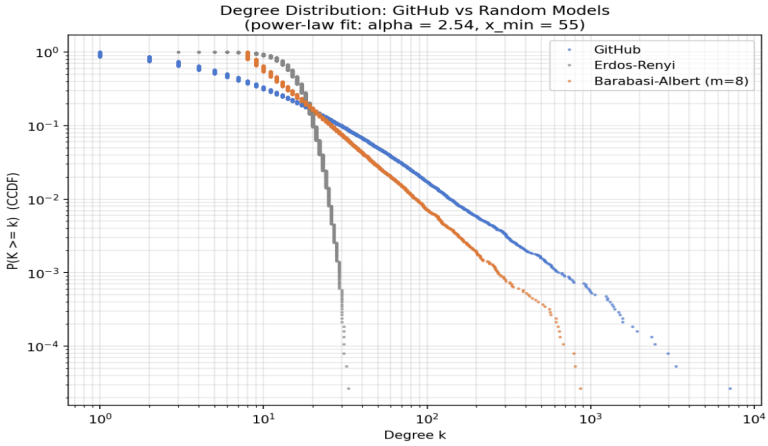
- מספר צמתים: 37,700
- מספר קשתות: 289,003
- צפיפות: 0.000407
- דרגה ממוצעת: 15.332
- רכיבי קשירות: 1

התפלגות התוויות בדאטה:

- פיתוח אתרים Web: 27,961 מפתחים (74.17%)
- למידת מכונה Machine Learning: 9,739 מפתחים (25.83%)



איור 1: התפלגות התוויות. בשל חוסר האיזון, ההערכה מתבססת על Macro F1 ו-ROC-AUC ולא על Accuracy בלבד.



איור 2: התפלגות הדרגות בסקלת לוג-לוג בהשוואה לרשתות אקראיות שקולות (Erdős–Rényi ו-Barabási–Albert). הזנב הכבד של רשת המפתחים בולט מול שני המודלים האקראיים.

אפיון מבני: הרשת מדגימה זנב כבד (איור 2): דרגת השיא היא 9,458, לעומת 34 ברשת Erdős–Rényi שקולה. התאמה סטטיסטית מעלה חוק חזקה עם $\alpha=2.54$, עדיף מובהק על התפלגות מעריכית אך בלתי ניתן להבחנה מלוג-נורמלית, ולכן נאפיין את הרשת כ"כבדת-זנב" ולא כ-scale-free. בנוסף, הרשת היא Small-World: התקבצות גבוהה פי ~420 מרשת אקראית, עם מרחק ממוצע קצר אף יותר (3.22 לעומת 4.13). תכונות אלו מצדיקות מודלים מבוססי-שכנות ומרמזות על תפקיד מרכזי לצמתי ה-Hub.
הקובץ musae_git_features.json מכיל 4,005 מאפייני תוכן בינאריים לצומת (repositories מסומני כוכב, מעסיק, מיקום). הם אינם משמשים כקלט בצנרת המרכזית, רק כנקודת ייחוס בניסוי ה-Ablation וכבסיס לגילוי תת-התמחויות.

מסגרת מתודולוגית

הניסוי מוגדר כ-Transductive Node Classification. כלומר, מבנה הגרף ידוע מראש עבור כל הצמתים, כולל צמתי הבדיקה, אך תוויות ה-test אינן משמשות בזמן האימון, בחישוב מאפייני train-label או בבחירת סף החלטה. זהו ניסוח מתאים לרשת חברתית כמו GitHub, שבה ניתן להכיר את קשרי המעקב של משתמשים גם כאשר תחום ההתמחות שלהם אינו ידוע.

מאפיינים מבוססי תוויות חושבו רק מתוך צמתי train:

- יחס שכני Web/ML עבור כל צומת.
- ספירת שכנים מתויגים מתוך train.
- יחסי Web/ML בתוך קהילה לפי train בלבד.

עיקרון זה נשמר גם בשיטות המתקדמות: ייצוגי DeepWalk נלמדים ללא תוויות כלל (מבנה הגרף בלבד), ב-GCN התוויות משמשות רק דרך פונקציית ההפסד על צמתי train, ובחירת ה-epoch המיטבי נעשית על validation פנימי (10% מה-train), ובניסוי חיזוי הקשרים, כל ההיוריסטיקות כולל זיהוי הקהילות, מחושבות על גרף האימון בלבד, לאחר הסרת הקשתות המוסתרות. כך נמנעת דליפת מידע בכל אחת ממשימות החיזוי.

פרוטוקול הערכה אחיד: כל הניסויים בעבודה, הן חיזוי הצמתים על כל גרסאותיו והן חיזוי הקשתות, רצים על אותן חמש חלוקות Train/Test מרובדות (70/30, seeds קבועים). התוצאות מדווחות כממוצע על חמש החלוקות, והבדל בין מודלים נחשב בעבודה זו לשיפור רק אם הוא מופיע בכל אחת מחמש החלוקות, ולא רק בממוצע.

אלגוריתמים ושיטה

- **הומופיליה ואסורטטיביות (Homophily & Assortativity):** הומופיליה היא העיקרון לפיו צמתים בעלי מאפיינים דומים נוטים להתחבר זה לזה בסבירות גבוהה יותר מאשר צמתים שונים. מדד האסורטטיביות מכמת נטייה זו באופן סטטיסטי על פני הרשת כולה. כצעד מקדים לחיזוי, בדקנו את שיעור הקשתות המחברות צמתים מאותה תווית (Web-Web או ML-ML) כדי לוודא שקיים סיגנל טופולוגי ראשוני שמצדיק את גישת ה-Network-Only.
- **מודל רוב שכנים (Neighbor Majority):** מודל זה מהווה קו בסיס (Baseline) גרפי-מקומי לבעיית החיזוי. האלגוריתם בוחן את סביבתו המיידית של כל צומת מטרה, וחוזה את התווית שלו בהתבסס על מחלקת הרוב בקרב השכנים הישירים שלו המשתייכים לקבוצת האימון (Train).
- **הפצת תוויות (Label Propagation):** זהו אלגוריתם מסוג למידה חצי-מונחית (Semi-supervised) המפיץ מידע על תוויות דרך קשתות הגרף. באלגוריתם זה, התוויות של צמתי האימון מקובעות מראש, והמידע מתפשט באופן איטרטיבי לאורך הקשתות אל הצמתים הלא-מתויגים בהתאם למבנה השכנות, עד להתכנסות. המימוש שלנו מקפיד שלא לעשות שימוש בתוויות המבחן (Test) בשום שלב של ההפצה, כדי למנוע דליפת מידע.
- **מאפייני גרף ומרכזיות (Graph Features):** עבור כל צומת חולצו מדדים טופולוגיים המשקפים את מיקומו וחשיבותו ברשת: דרגה, מקדם התקבצות, Core Number, PageRank, ספירת משולשים, ציוני HITS (Hubs/Authorities) וקירוב מבוסס-מדגם של Betweenness Centrality (חישוב מדויק אינו ישים בגודל רשת זה). מדדים אלו, יחד עם יחסי התוויות בסביבת הצומת, הוזנו כפיצ'רים לרגרסיה לוגיסטית.
- **זיהוי קהילות (Louvain Community Detection):** אלגוריתם Louvain הוא שיטה חמדנית ואגריגטיבית למציאת קהילות ברשתות גדולות, הפועלת באמצעות מקסום פונקציית המודולריות (Modularity) של הגרף. מודולריות מודדת את צפיפות הקשרים בתוך הקהילות לעומת צפיפות הקשרים שהייתה מצופה בגרף אקראי בעל אותה התפלגות דרגות. הרצת האלגוריתם זיהתה בגרף שלנו 31 קהילות בעלות ציון מודולריות של כ-0.4534 (מבנה הקהילות והקשרים ביניהן מומחש ויזואלית באיור 3), נתון המעיד על קיומו של מבנה קהילתי מובהק ברשת המפתחים.
- **מודל לוגיסטי משולב (Graph + Community Features):** שיא הגישה של הנדסת הפיצ'רים הידנית: שילוב המאפיינים הגרפיים המקומיים עם מאפייני הקהילה של Louvain, כך שהמודל לומד בו-זמנית מהסביבה המיידית של הצומת ומההקשר הקהילתי-גלובלי שלו. מזהי הקהילה קודדו ב-One-Hot כדי שלא יתפרשו כמשתנה סדור, וחוסר

האיזון בנתונים טופל בפונקציית מחיר ממושקלת (class_weight="balanced"), המשפרת משמעותית את זיהוי מחלקת המיעוט (Recall).

- **ייצוגים נלמדים (DeepWalk):** נלמד וקטור בן 128 ממדים לכל צומת מתוך הילוכים אקראיים (10 לצומת, באורך 80) המוזנים ל-Word2Vec (skip-gram). הייצוג נלמד ללא תוויות וללא תוכן, מבנה הרשת בלבד ועליו מאומנת רגרסיה לוגיסטית, לבדו ובשילוב המאפיינים הידניים.
- **רשת נוירונים גרפית (GCN):** GCN דו-שכבתי (שדה ראייה עד מרחק 2), ממומש ב-PyTorch עם מטריצה דלילה ומאומן על הגרף המלא עם משקולות מחלקה. נבחנו שתי גרסאות קלט- מאפיינים מבניים בסיסיים לעומת ייצוגי DeepWalk כדי לבודד את תרומת הארכיטקטורה מתרומת הייצוג. בנוסף נבחנה ארכיטקטורת GraphSAGE (Hamilton et al., 2017) עם אגרגציית mean, ליצירת מערך 2×2 המבודד ארכיטקטורה מייצוג.
- **מודלי Ablation (רשת מול תוכן):** השוואה תחת אותו מסווג של שלושה מקורות מידע: תוכן בלבד, רשת בלבד (המודל המשולב), ושילובם (Hybrid).
- **גילוי תת-התמחויות:** אשכול לא-מונחה של מאפייני התוכן (TruncatedSVD ואז KMeans, k לפי silhouette); ההתאמה בין האשכולות, קהילות Louvain והתוויות נמדדה ב-NMI ו-ARI.
- **חיזוי קשרים (Link Prediction):** 10% מהקשתות הוסתרו ומולן נדגמו זוגות לא-מחוברים; כל זוג דורג בחמש היוריסטיקות (Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment, Same-Community), המחושבות על גרף האימון בלבד. התוצאות רובדו לפי תוויות הקצוות לחיבור עם שאלת ההומופיליה.
- **מודלי אפס ומובהקות מבנית:** מובהקות ההומופיליה נבדקה מול ערבוב תוויות (1,000 פרמוטציות) ומול ערבול קשתות משמר-דרגות, ומובהקות המודולריות מול הגרפים המעורבלים.

ניסויים

הניסויים הורצו על 5 חלוקות Train/Test מרובדות ביחס 70/30 (seeds קבועים).
נבדקו שלושה-עשר מודלי חיזוי, המסודרים בסולם לפי סוג המידע שהם מנצלים:

- Majority Baseline
- Neighbor Majority
- Label Propagation
- Logistic Regression - Graph Features Only
- Logistic Regression - Graph + Community Features
- GCN - קלט מבני
- GraphSAGE - קלט מבני
- Logistic Regression - DeepWalk
- Logistic Regression - Content Features Only (ייחוס לניסוי ה-Ablation)
- GraphSAGE - קלט DeepWalk
- GCN - קלט DeepWalk
- Logistic Regression - DeepWalk + Graph + Community
- Logistic Regression - Hybrid (רשת + תוכן)

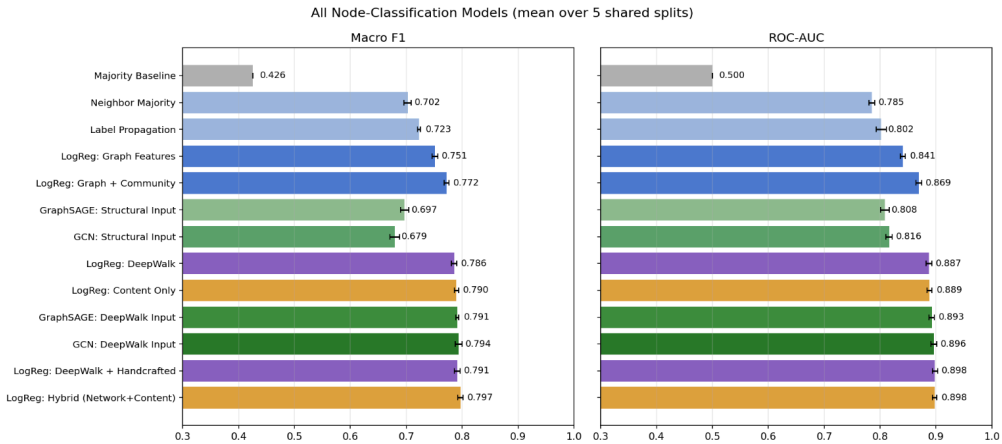
בנוסף, עבור המודל המשולב בוצע כיול סף החלטה; הסף נבחר על validation בלבד לאחר פיצול נוסף של train, ולא על test.

תוצאות (ממוצע על 5 חלוקות)

מודל	Accuracy	Precision	Recall	F1	Macro F1	ROC-AUC
Majority Baseline	0.7416	0.0000	0.0000	0.0000	0.4258	0.5000
Neighbor Majority	0.8188	0.8312	0.3747	0.5165	0.7025	0.7851
Label Propagation	0.8285	0.8495	0.4085	0.5517	0.7228	0.8021

LogReg - Graph Features	0.8036	0.6096	0.6672	0.6371	0.7512	0.8410
LogReg - Graph + Community	0.8168	0.6255	0.7251	0.6716	0.7723	0.8694
GCN - קלט מבני	0.7097	0.4634	0.7757	0.5800	0.6791	0.8160
GraphSAGE - קלט מבני	0.7385	0.4961	0.7136	0.5851	0.6971	0.8085
LogReg - DeepWalk	0.8250	0.6326	0.7694	0.6943	0.7859	0.8874
LogReg - Content Only	0.8292	0.6417	0.7671	0.6988	0.7898	0.8887
GraphSAGE - קלט DeepWalk	0.8289	0.6376	0.7826	0.7026	0.7912	0.8926
GCN - קלט DeepWalk	0.8307	0.6397	0.7895	0.7067	0.7938	0.8961
LogReg - + DeepWalk ידני	0.8285	0.6361	0.7852	0.7028	0.7911	0.8982
LogReg - Hybrid (רשת+תוכן)	0.8356	0.6537	0.7732	0.7085	0.7970	0.8975

כל מעבר בסולם המרכזי משפר את קודמו בכל אחת מחמש החלוקות. המודלים הרשתיים החזקים ביותר, DeepWalk+ידני ושני ה-GNN עם קלט DeepWalk, מתכנסים יחד עם ה-Hybrid לרצועה צרה של ROC-AUC 0.893–0.898.
ההשוואה המלאה מוצגת באיור 3.



איור 3: השוואת כל מודלי חיזוי הצמתים (ממוצע על 5 חלוקות; פסי שגיאה = סטיית תקן). משמאל Macro F1, מימין ROC-AUC.
ניכרת עלייה מדורגת מקו הבסיס ועד הייצוגים הנלמדים, והתכנסות ארבעת המודלים המובילים לרף משותף.

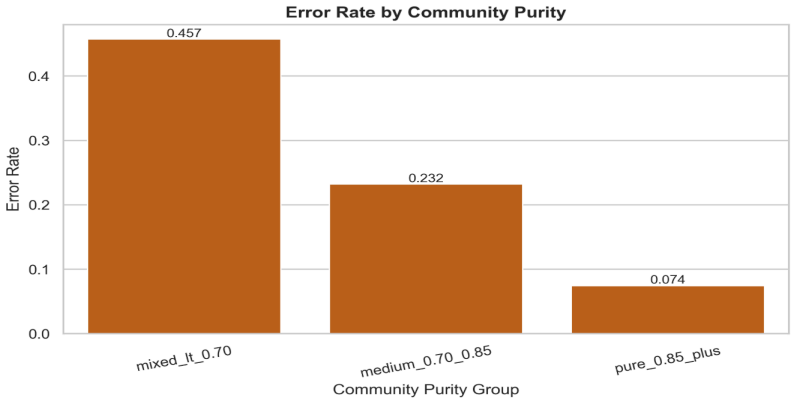
כיול סף החלטה

עבור המודל המשולב בוצע כיול סף החלטה על סט Validation בלבד. הכיול הוא בעיקרו החלפה בין דיוק לכיסוי: העלאת הסף ל-0.60 שיפרה את ה-Precision (0.667 לעומת 0.617) על חשבון ה-Recall (0.663 לעומת 0.719), עם F1 כמעט זהה, כאשר את עיקר העבודה עשו המשקולות המאזנות עוד לפני הכיול. לאחר הכיול נותרו 967 טעויות Web→ML ו-985 טעויות ML→Web.

ניתוח שגיאות

עבור המודל המשולב המכויל בוצע ניתוח שגיאות לפי שלושה ממדים:

1. דרגת הצומת: צמתים בעלי דרגה נמוכה קשים יותר לחיזוי, משום שיש פחות מידע שכנותי. עם זאת, גם בקבוצת הדרגות הנמוכות ביותר (degree 0–2) התקבל F1 של 0.6423 לאחר כיול הסף, והביצועים משתפרים בהדרגה עם העלייה בדרגה.
2. טוהר קהילה: קהילות מעורבות יוצרות שיעור שגיאות גבוה יותר (איור 4):
   - קהילות עם purity < 0.70: שיעור שגיאה של 0.4571 (35 צמתים, 16 שגיאות).
   - קהילות עם purity בין 0.70 ל-0.85: שיעור שגיאה של 0.2322 (6,951 צמתים, 1,614 שגיאות).
   - קהילות טהורות (purity ≥ 0.85): שיעור שגיאה נמוך של 0.0745 (4,324 צמתים, 322 שגיאות).



איור 4: שיעור שגיאות החיזוי של המודל כתלות בטוהר הקהילה (Community Purity).

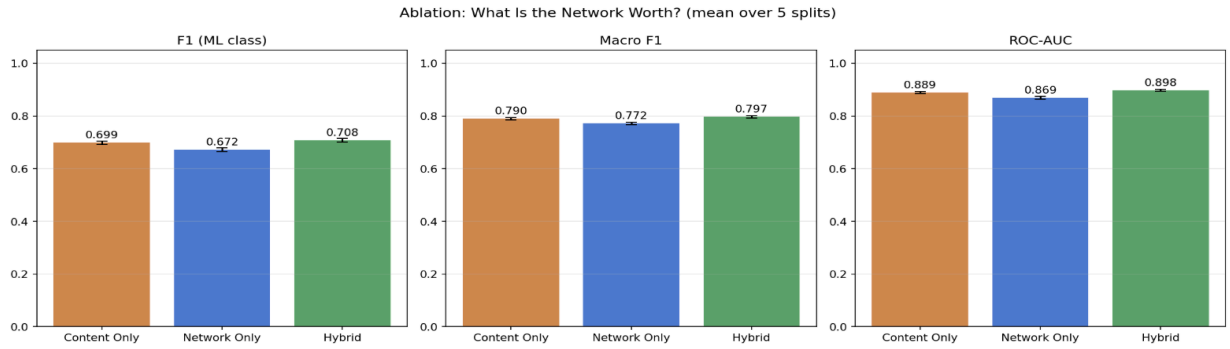
3. כיוון הטעות: המשקולות המאזנות צמצמו משמעותית את פספוסי מפתחי ה-ML, אם כי נותרה נטייה קלה לסווגם כ-Web עקב חוסר האיזון בנתונים.

שלושת ממדי השגיאה מצביעים על גורם יסודי אחד: מחסור במידע שכנותי. דרגה נמוכה, קהילות מעורבות ופספוסי ML הם כולם ביטויים של שכונות דלילות או דו-משמעיות. ממצא זה יתאשש בהמשך משני כיוונים בלתי-תלויים, קשתות ML-ML יתגלו כקשות ביותר לחיזוי, ומודלי האפס יראו שמפתחי ML מחזיקים חלק קטן מקצוות הקשתות. הקושי בזיהוי מחלקת המיעוט אינו מגבלה של מודל ספציפי אלא תכונה מבנית של הרשת.

תוצאות לפי שאלות המחקר

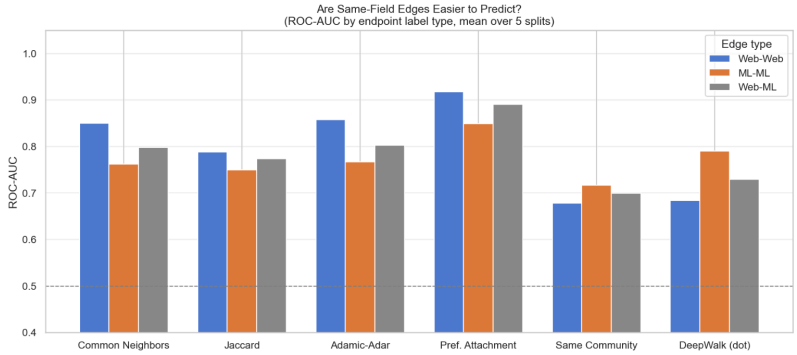
שאלה 1- חיזוי צמתים: נענתה בהרחבה בסעיפים הקודמים. תמצית: מבנה הרשת לבדו מאפשר חיזוי ברמה גבוהה, בעלייה העקבית בכל אחת מחמש החלוקות, משכנות מקומית (0.785 AUC) ועד ייצוגים נלמדים (≈0.90), שם ארבעת המודלים המובילים מתכנסים לתקרה משותפת. שלוש השאלות הבאות משלימות את התמונה.

שאלה 2- רשת מול תוכן: מאפייני התוכן לבדם (0.889 AUC) עדיפים במעט על הפיצ'רים הרשתיים הידניים (0.869), אך DeepWalk סוגר את הפער לחלוטין (0.887, הפרש ממוצע של 0.001 הקטן מסטיית התקן שבין החלוקות): מבנה קשרי המעקב מכיל את אותו מידע על ההתמחות, נדרש רק ייצוג חזק לחלצו. ההיברידי עולה על שניהם במעט (+0.009) בכל חמש החלוקות, עדות לחפיפת מידע גבוהה אך לא מלאה. ממצא משלים: קהילות Louvain מיושרות עם אשכולות התוכן (NMI 0.257) פי ~2.4 יותר מאשר עם התווית הבינארית (0.106), המשימה הבינארית היא רצפה, לא תקרה, של המידע ברשת.



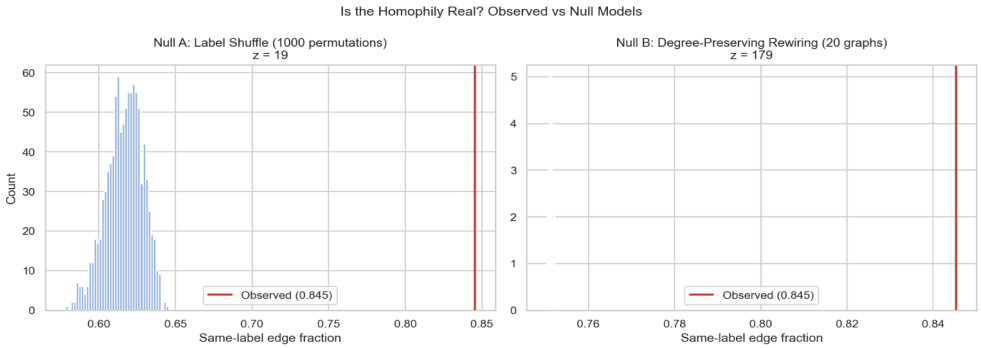
איור 5: השוואת מקורות המידע (ממוצע על 5 חלוקות): תוכן בלבד, רשת בלבד והמודל ההיברידי.

שאלה 3- חיזוי קשתות: קשרי המעקב ניתנים לחיזוי, עם Preferential Attachment בראש (0.910 AUC), עקבי עם הזנב הכבד של הרשת. ההשערה שקשתות תוך-תחומיות צפויות יותר הופרכה: בהיוריסטיקות המקומיות Web-Web צפוי יותר מ-ML-ML (איור 6), כלומר החיזוי עוקב אחר צפיפות שכונתית ולא אחר דמיון תוויות. שני הציונים מבוססי-הדמיון, שיוך לקהילה (0.690) ו-DeepWalk (0.694), הם החלשים ביותר והיחידים שמתהפכים בריבוד: ייצוגים נלמדים שולטים בסיווג צמתים אך לא בחיזוי קשרים.



איור 6: ROC-AUC של היוריסטיקות חיזוי הקשרים בריבוד לפי תוויות הקצוות. בהיוריסטיקות המקומיות קשתות Web-Web צפויות יותר מ-ML-ML צפיפות שכונתית, לא דמיון תחומי, מניעה את החיזוי; Same-Community היא היחידה שמתהפכת.

שאלה 4- תוקף מבני: ההומופיליה (84.5%) עומדת מול שני מודלי אפס: ערבוב תוויות (צפי 61.7%) וערבול קשתות משמר-דרגות (צפי 75.1%), כשאף אחת מדגימות האפס אינה מתקרבת לערך הנצפה. הפער בין שני המודלים הוא ממצא בפני עצמו: כ-60% מההומופיליה מוסברים בהבדלי דרגות בין המחלקות, והעודף, כ-9.4 נקודות, משקף העדפה תוך-תחומית אמיתית. גם המבנה הקהילתי בולט: מודולריות 0.453 מול 0.189 ברשתות המעורבלות.



איור 7: שיעור הקשתות התוך-תחומיות תחת שני מודלי אפס- ערבוב תוויות (משמאל) וערבול קשתות משמר-דרגות (מימין) לעומת הערך הנצפה (קו אדום, 84.5%). ההומופיליה מובהקת בשני המודלים.

מגבלות העבודה

- הדאטה נאסף ביוני 2019 ואינו בהכרח מייצג את GitHub כיום, והגרף סטטי ואינו כולל התפתחות בזמן.
- המשימה בינארית בלבד. ניתוח תת-ההתמחויות ממתן זאת אך הוא חקרני (silhouette נמוך) ואינו מחליף תוויות רב-מחלקתיות אמיתיות.
- התוויות נגזרו מתיאורי תפקידים ועלולות לכלול רעש. תקרת הביצועים המשותפת (AUC≈0.90) עקבית עם השערה זו.
- התפלגות הדרגות אינה ניתנת להבחנה מלוג-נורמלית, ולכן נמנענו מהכרזת scale-free גורפת.
- ציון ה-DeepWalk בחיזוי קשרים חושב במכפלה פנימית פשוטה; שיטות עשירות יותר עשויות לצמצם את הפער מול ההיוריסטיקות.

מסקנות

ארבע שאלות המחקר נענו בחיוב, והתמונה המצטברת מובילה למסקנה אחת: לרשת חברתית-מקצועית יש 'טביעת אצבע' תחומית עמוקה: היא ניכרת במבנה הקשרים, בקהילות ובדינמיקת יצירת הקשרים עצמה, וניצולה המלא תלוי באיכות ייצוג הרשת יותר מאשר במורכבות המודל. שלושה לקחים רוחביים: ייצוג נלמד גובר על הנדסת פיצ'רים ידנית, מידע מבני ומידע תוכני חופפים ברובם אך לא במלואם, ותקרת הביצועים המשותפת מרמזת שהחסם הוא איכות התוויות ולא המידע שברשת.

מקורות

1. Rozemberczki, B., Allen, C., & Sarkar, R. (2019). Multi-scale Attributed Node Embedding (MUSAE).
2. McPherson, M., Smith-Lovin, L., & Cook, J. M. (2001). Birds of a Feather: Homophily in Social Networks. Annual Review of Sociology.
3. Blondel, V. D., et al. (2008). Fast unfolding of communities in large networks.
4. Perozzi, B., Al-Rfou, R., & Skiena, S. (2014). DeepWalk: Online Learning of Social Representations. KDD.
5. Kipf, T. N., & Welling, M. (2017). Semi-Supervised Classification with Graph Convolutional Networks. ICLR.
6. Liben-Nowell, D., & Kleinberg, J. (2003). The Link Prediction Problem for Social Networks. CIKM.
7. Clauset, A., Shalizi, C. R., & Newman, M. E. J. (2009). Power-law distributions in empirical data. SIAM Review.
8. Broido, A. D., & Clauset, A. (2019). Scale-free networks are rare. Nature Communications.
9. Page, L., et al. (1999). The PageRank Citation Ranking.
10. Hamilton, W., Ying, R., & Leskovec, J. 2017)). Inductive Representation Learning on Large Graphs. NeurIPS.
11. מצגות ותרגולי הקורס.