סיווג תחום התמחות של מפתחי GitHub באמצעות קשרי מעקב הדדיים ברשת

נועה יריין לוי ג'ימי חלאוי אופיר אטיאס

208101196 208301176 211446935

מרצה: ד"ר אבנר פריאל

הנתונים: MUSAE GitHub Social Network · תמונת מצב מיוני 2019

37,700	289,003	13	5
מפתחים	קשרים הדדיים	מודלי סיווג	חלוקות ניסוי

תקציר מנהלים

העבודה בוחנת כמה מידע על תחום ההתמחות של מפתחי GitHub מצוי במבנה רשת המעקב ההדדית. הגרף כולל 37,700 צמתים ו־289,003 קשתות, ותווית היעד היא Web או Machine Learning. המחקר משלב תיאור מבני, מרכזיות, Louvain, סיווג צמתים, הטמעות DeepWalk/Node2Vec, שחזור קשתות ומודלי אפס. כל תוצאות הסיווג והשחזור ממוצעות על פני חמש חלוקות קבועות, ותוויות test אינן משמשות לחישוב מאפיינים, לכיול סף או לאימון.

0.845	0.909	0.924	0.453
שיעור קשתות תוך־תחומיות	ROC-AUC מיטבי בסיווג	AUC מיטבי בשחזור קשתות	מודולריות Louvain

המסקנה המרכזית: קשרי המעקב ההדדיים מכילים אות חיזוי משמעותי ביחס לתחום המקצועי. קהילות והטמעות מבניות מוסיפות מידע, ותוכן מוסיף אות משלים. עם זאת, הממצאים תיאוריים וחיזויים: הם אינם מוכיחים סיבתיות, והשחזור אינו תחזית של קשרים עתידיים.

התוצאות המרכזיות הן ROC-AUC של 0.869 למאפייני גרף וקהילה, 0.898 לשילוב רשת ותוכן ו־0.900 לשילוב DeepWalk עם מאפייני גרף וקהילה. במחקר ההרחבה, GCN הגיע ל־ROC-AUC של 0.9087 ו־GraphSAGE ל־0.9083, ושניהם הציגו שיפור קטן אך עקבי ביחס למודלי הליבה החזקים. Label Propagation הגיע ל־0.8025 והיה חלש יותר, ולכן הומופיליה מקומית לבדה אינה מספיקה להשגת התוצאות הטובות ביותר. בניסוי אשכולות התוכן התקבלה חלוקה יציבה לשלושה אשכולות, אך ההפרדה הייתה חלשה ולכן אין בסיס לפרש אותם כתתי־תחומים מקצועיים ברורים. בשחזור הקשתות הוביל Preferential Attachment עם ROC-AUC של 0.924, ההומופיליה הייתה 0.845 והמודולריות של Louvain הייתה 0.453. כלל הממצאים הם תיאוריים וחיזויים ואינם מוכיחים קשר סיבתי.

1. מבוא, מוטיבציה והגדרת הבעיה

GitHub הוא גם רשת חברתית־מקצועית: מפתחים עוקבים זה אחר זה ומתגבשים סביב טכנולוגיות ותחומי עניין. מכאן שאלת המחקר: האם אפשר ללמוד על תחום המפתח מתוך מיקומו ברשת, לפני שימוש בקוד או בתיאור הפרופיל?

כל צומת הוא מפתח וכל קשת לא־מכוונת מייצגת מעקב הדדי; התווית היא Web או Machine Learning. מסגרת אחת מאפשרת לבחון הומופיליה, קהילות, מרכזיות, סיווג ושחזור קשתות. מבחינה מדעית הפרויקט בודק קשר בין מבנה רשת לזהות מקצועית; מבחינה יישומית הוא מדגים אותות שעשויים לתמוך בהמלצות, גילוי קהילות ואיתור מומחים, בלי לבנות מערכת החלטה למשתמשים.

גבולות הפרשנות: הנתונים הם תמונת מצב ללא סדר זמנים. לכן אין להסיק שהתחום יצר את הקשר או שהקשר שינה את התחום.

2. עבודה קשורה

העבודה נשענת על מספר קווי מחקר מרכזיים. מאגר MUSAE והמחקר של Rozemberczki, Allen ו־Sarkar מספקים את נתוני רשת GitHub ואת מסגרת סיווג הצמתים שעליה מבוסס הפרויקט [1]. אלגוריתם Louvain משמש לזיהוי קהילות ולמדידת מודולריות, וכך מאפשר לבדוק את הקשר בין המבנה הקהילתי לבין תחומי ההתמחות [2]. DeepWalk ו־Node2Vec לומדים ייצוגים מבניים של צמתים באמצעות הילוכים אקראיים, והם משמשים להשוואה בין מאפייני רשת ידניים לבין ייצוגים נלמדים [3,4]. מסגרת ה־Link Prediction של Liben-Nowell ו־Kleinberg מנחה את ניסוי שחזור הקשתות ואת השימוש במדדים Common Neighbors, Jaccard, Adamic-Adar ו־ Preferential Attachment [5]. בדיקת ההתפלגות כבדת־הזנב מבוססת על Clauset ואחרים [6], ואילו PageRank ומודלי Erdős–Rényi, Barabási–Albert ו־Watts–Strogatz משמשים כנקודות ייחוס לניתוח מרכזיות ומבנה הרשת [7–10].

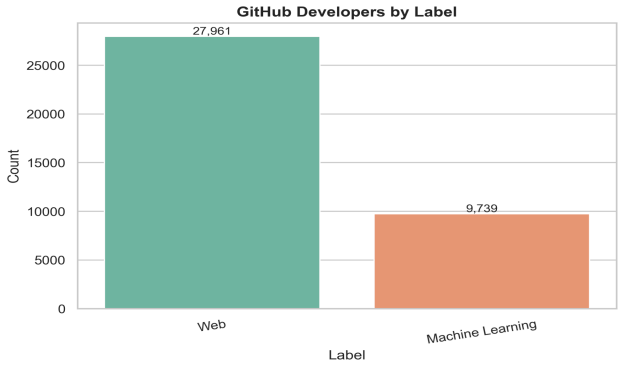
מחקר ההרחבה מוסיף שלוש משפחות שיטות. Label Propagation מפיץ תוויות מצומתי האימון דרך קשרי הרשת ומשמש קו בסיס חציי־מונחה המבוסס על הומופיליה מקומית [11]. GCN ו־GraphSAGE מבצעים Message Passing ולומדים ייצוגי צמתים באמצעות צבירת מידע מהשכנים, מעבר למאפיינים ידניים ולהטמעות המבוססות על הילוכים אקראיים [12,13]. בנוסף, TruncatedSVD ו־K-means משמשים לבחינה בלתי־מונחית של מבנה עדין יותר בתוך מאפייני התוכן [14,15]. ההרחבות נבדקות בנפרד מתוצאות הליבה ואינן משנות בדיעבד את שאלות המחקר המקוריות.

3. מסד הנתונים ובקרת איכות

הנתונים נלקחו מ־MUSAE GitHub Social Network ונאספו מה־API הציבורי של GitHub ביוני 2019. לאחר טעינה נבנה גרף לא־מכוון. בקרת האיכות מאשרת שאין קשתות עצמיות, אין כפילויות, אין תוויות חסרות וכל 37,700 הצמתים נמצאים ברכיב קשירות יחיד.

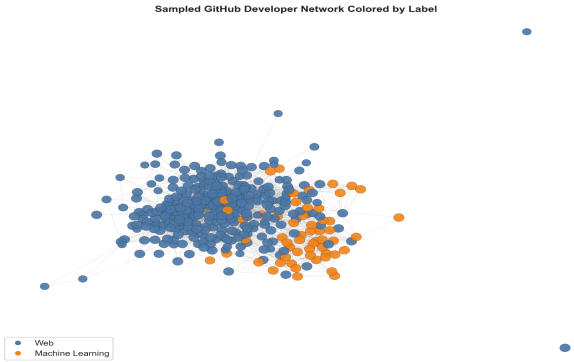
נוסף למבנה הרשת, לכל מפתח קיים וקטור תוכן בינארי ודליל בן 4,005 ממדים, המבוסס על מאפייני MUSAE שנגזרו ממידע ציבורי בפרופיל המשתמש. מאפיינים אלה מהווים מקור מידע נפרד ממבנה הקשתות ומאפשרים להשוות בין יכולת החיזוי של הרשת, של התוכן ושל שילוב ביניהם. מאחר שמדובר במאפיינים מקודדים ודלילים, לא לכל אינדקס בווקטור קיים פירוש אנושי ישיר הזמין במאגר.

מדד	ערך
מספר צמתים	37,700
מספר קשתות	289,003
דרגה ממוצעת	15.332
צפיפות	0.0004067
מספר רכיבי קשירות	1
קשתות עצמיות / כפילויות / תוויות חסרות	0 / 0 / 0
דרגה מרבית	9,458



איור 1. התפלגות תוויות התחום: 27,961 מפתחי Web (74.17%) ו־9,739 מפתחי Machine Learning (25.83%).

הדאטה אינו מאוזן: כשלושה רבעים מהצמתים מסווגים כ־Web. לכן Accuracy לבדו עלול להטעות. המדדים המרכזיים הם ROC-AUC ו־Macro F1; בנוסף מדווחים Precision, Recall ו־F1 למחלקת ML.



איור 2. דגימה חזותית של הרשת לפי תווית. הצבעים מציגים את התחומים, אך התרשים הוא המחשה בלבד ואינו בסיס להסקה כמותית.

4. שאלות מחקר

- **שאלת מחקר 1 - עד כמה שכנות, מרכזיות וקהילות מאפשרות לסווג את תחום המפתח מתוך מבנה הרשת?**
- **שאלת מחקר 2 - מהו הערך היחסי של רשת, תוכן והטמעות DeepWalk/Node2Vec, ומה מוסיף שילוב ביניהם?**
- **שאלת מחקר 3 - עד כמה ניתן לשחזר קשתות שהוסתרו, והאם קשתות תוך־תחומיות קלות יותר לשחזור מקשתות בין־תחומיות?**
- **שאלת מחקר 4 - האם ההמופיליה והמודולריות חריגות ביחס למודלי אפס, ואילו מאפיינים משחזרים מודלי רשת קלאסיים?**

5. מסגרת מתודולוגית - שלב אחר שלב

הניתוח תוכנן כך שכל שלב יהיה ניתן לשחזור ושלא תהיה דליפת מידע מקבוצת הבדיקה. להלן התהליך במילים פשוטות:
שלב 1 – הכנת הנתונים: טעינת הצמתים, הקשתות, התוויות ומאפייני התוכן; בדיקת ערכים חסרים, כפילויות, קשתות עצמיות וקשירות הגרף.
שלב 2 – ניתוח מבני: חישוב דרגות, צפיפות, התקבצות, מרחקים ומדדי המרכזיות Degree, PageRank, Betweenness ו־HITS Hub; השוואה למודלי רשת קלאסיים.
שלב 3 – ניתוח קהילות: הפעלת Louvain, חישוב מודולריות וניתוח הרכב הקהילות. כל מאפיין התלוי בתוויות מחושב מתוויות האימון בלבד.
שלב 4 – סיווג צמתים: ביצוע חמש חלוקות מרובדות ביחס 70/30, עם ה־seeds 42, 7, 21, 84 ו־123, והערכת מודלי Logistic Regression מול קווי בסיס.
שלב 5 – השוואת מקורות מידע: השוואת מאפייני רשת ידניים, מאפייני תוכן, DeepWalk, Node2Vec ושילובים ביניהם על אותן חלוקות ניסוי.
שלב 6 – שחזור קשתות: בכל seed נשמר עץ פורש, מוסתרות 28,900 קשתות חיוביות ונבחר מספר זהה של non-edges לצורך הערכה מאוזנת.
שלב 7 – מודלי אפס: ביצוע 1,000 ערבובי תוויות ו־20 גרפים משמרי־דרגות. ערך ה־p האמפירי מחושב באמצעות הנוסחה (b+1)/(B+1).
שלב 8 – הרחבות: Label Propagation, GCN ו־GraphSAGE נבדקים על אותן חמש חלוקות. בנוסף, מאפייני התוכן מצומצמים באמצעות TruncatedSVD ונבדקים באמצעות K-means עבור k=3..10.
שלב 9 – דיווח תוצאות: הצגת ממוצע וסטיית תקן על פני חמש החלוקות, לצד פרשנות ומגבלות לכל שאלת מחקר ולמחקר ההרחבה.

5.1 מניעת דליפת מידע

המסגרת היא Transductive Node Classification: מבנה הגרף ידוע עבור כל הצמתים, אך תוויות קבוצת הבדיקה מוסתרות לאורך כל תהליך האימון. יחס שכני Web ו־Machine Learning, מספר השכנים המתויגים והרכב התוויות בקהילה מחושבים בכל split באמצעות תוויות ה־train בלבד. כל פעולת preprocessing התלויה בנתונים מותאמת על קבוצת האימון בלבד, וסף ההחלטה נבחר באמצעות validation פנימי מתוך ה־train, ללא שימוש בקבוצת ה־test. בניסוי שחזור הקשתות, DeepWalk ו־Node2Vec מאומנים על גרף האימון לאחר הסרת קשתות הבדיקה, כך שההטמעות אינן מכילות את הקשתות שאותן הן נדרשות לשחזר.

גם במחקר ההרחבה, קבוצת האימון החיצונית מחולקת ל־inner-train ול־validation לצורך בחירת ההגדרות ומספר ה־epochs. לאחר הבחירה, המודל מאומן מחדש על כל תוויות האימון החיצוני. תוויות ה־test מוסתרות עד לסיום האימון הסופי. בדיקות דליפת המידע אישרו שבכל חמש החלוקות מספר תוויות ה־test שנחשפו במהלך בחירת המודל או האימון היה אפס.

5.2 מודלי הסיווג

מודלי בסיס, רשת ותוכן

מודל	קלט	תפקיד
Majority Baseline	שכיחות תוויות ב־train	קו בסיס ללא מידע מבני
Neighbor Majority	תוויות של שכני train	אות שכונתי מקומי
Graph-only	מרכזיות ומאפייני מבנה	פיצ'רים רשת ידניים
Graph + Community	מבנה וסטטיסטיקות קהילה	מודל הרשת הידני החזק
Content-only	מאפייני תוכן דלילים	מדידת כוח החיזוי של התוכן ללא מידע מהקשרים

Hybrid	רשת + תוכן	בדיקת מידע משלים

בנוסף נבדק אם DeepWalk ו־Node2Vec לומדים מידע מבני שימושי, ואם שילוב ההטמעות עם מאפייני הגרף והקהילה משפר את יכולת הסיווג.

הטמעות ושילובי ייצוגים

מודל	קלט	תפקיד
DeepWalk	הטמעת הילוכים אחידים	ייצוג מבני נלמד
Node2Vec	הטמעת הילוכים מוטים	ייצוג מבני נלמד
DeepWalk + Graph + Community	הטמעה + ידני	שילוב ייצוגים
Node2Vec + Graph + Community	הטמעה + ידני	שילוב ייצוגים

פרמטרי ההטמעה זהים ככל האפשר לצורך השוואה: 3 הילוכים לכל צומת, אורך הילוך 40, ממד 64, חלון 5 ו־5 epochs. ב־Node2Vec נבחרו p=1 ו־q=2.

5.3 פרוטוקול שחזור הקשתות

מטרת הניסוי היא לשחזר קשתות שהוסתרו מתמונת מצב סטטית של הרשת, ולא לחזות קשתות עתידיות. בכל חלוקה נשמרות 37,699 קשתות של עץ פורש, כדי להבטיח שגרף האימון יישאר קשיר. מתוך שאר הקשתות מוסתרות 28,900 קשתות חיוביות, המהוות כ־10% מכלל הקשתות. מולן נדגם מספר זהה של non-edges, תוך התאמה לשלושת סוגי הזוגות: Web–Web, Machine Learning–Machine Learning ו־Web–Machine Learning. גרף האימון הסופי כולל 260,103 קשתות, רכיב קשירות יחיד וללא צמתים מבודדים.

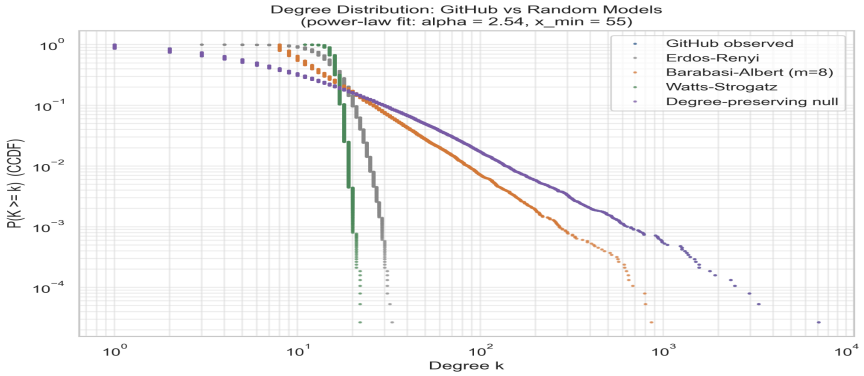
5.4 פרוטוקול ההרחבות

Label Propagation, GCN ו־GraphSAGE הוערכו על אותן חמש חלוקות 70/30 ועל אותם מדדים של מודלי הליבה: ROC-AUC, Macro-F1, F1, Balanced Accuracy, Precision ו־Recall. בכל split, 26,390 צמתים שימשו לאימון חיצוני ו־11,310 לבדיקה; מתוך האימון הוקצו 21,112 צמתים ל־inner-train ו־5,278 ל־validation. בחירת ההגדרות ועצירת האימון התבצעו באמצעות validation בלבד. GCN ו־GraphSAGE נבדקו בתרחיש transductive: מבנה הגרף ומאפייני הצמתים ידועים, אך תוויות ה־test מוסתרות. לא בוצעה הערכה של צמתים חדשים ולכן לא נטענת יכולת inductive.

בניסוי התוכן, המטריצה הדלילה בגודל 37,700×4,005 צומצמה ל־64 רכיבי TruncatedSVD, ששמרו 55.9% מן השונות. מספר האשכולות נבחר באמצעות Silhouette מתוך k=3..10, משום שהמטרה הייתה לחפש חלוקה עדינה יותר מהתווית הבינארית. יציבות החלוקה נבדקה בין חמישה seeds באמצעות Adjusted Rand Index. תוויות התחום לא שימשו לאימון האשכולות או לבחירת k.

6. מבנה הרשת, מרכזיות וקהילות

הרשת דלילה מאוד במונחי צפיפות, אך קשירה וקצרה יחסית: המרחק הממוצע שנמדד הוא 3.218. דרגת השיא, 9,458, רחוקה מאוד מן הממוצע ומצביעה על ריכוז קשרים אצל מספר קטן של צמתים.



איור 3. התפלגות הדרגות של רשת GitHub בסקלת לוג־לוג, בהשוואה למודלי Erdős–Rényi, Barabási–Albert, Watts–Strogatz ולגרף משמר־דרגות. הרשת הנצפית מציגה זנב כבד וריכוז גבוה של קשרים במספר קטן של צמתים.

התאמת Power Law עבור דרגות שמעל xmin=55 נותנת α=2.544. ההתאמה עדיפה בבירור על התפלגות מעריכית, אך ההשוואה להתפלגות לוג־נורמלית אינה מובהקת סטטיסטית (Likelihood Ratio=0.0127, p=0.7826). לכן המסקנה הזהירה היא שהתפלגות הדרגות כבדה־זנב; אין בסיס מספיק לקבוע שהרשת היא scale-free.

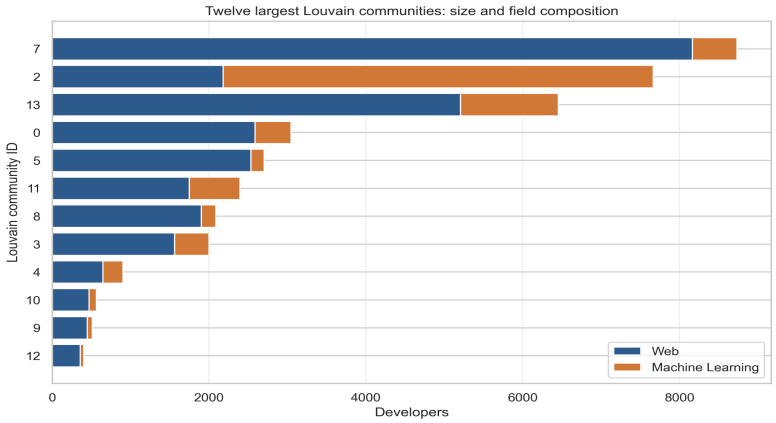
6.1 מרכזיות

Degree ו־PageRank מדגישים צמתים עתירי קשרים; Betweenness מדגיש גשרים בין אזורים. חפיפת Jaccard בין 20 המובילים ב־Degree וב־PageRank היא 1.000, ובין Degree ל־Betweenness 0.600.

ב-Degree וב-PageRank מוביל dalinhuang99, Node 31890, שדרגתו 9,458. ב-Betweenness מוביל nfultz, Node 27803, שדרגתו 7,085.

6.2 קהילות

בשלב זה נבחן אם החלוקה המבנית לקהילות מתיישבת עם הרכב תחומי ההתמחות של המפתחים.

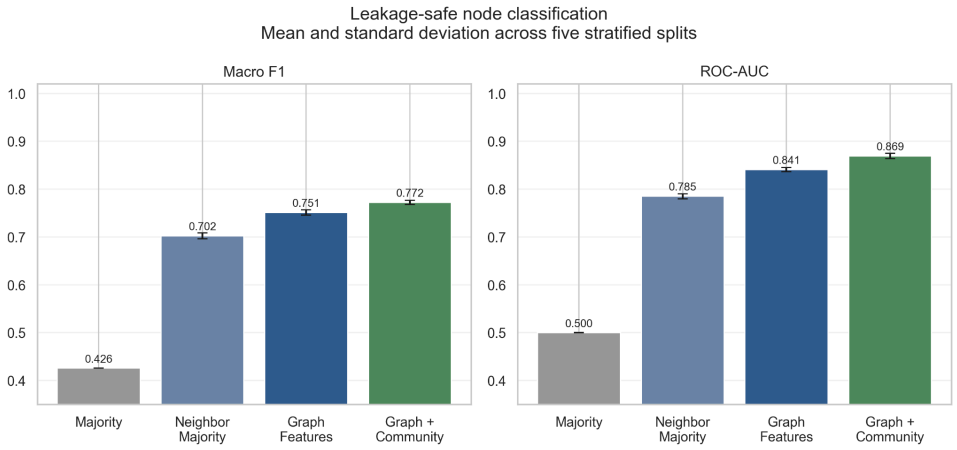


איור 4. שתים־עשרה קהילות Louvain הגדולות: גודל והרכב התוויות בכל קהילה.

Louvain מצא 31 קהילות עם מודולריות 0.453. הקהילה הגדולה כוללת 8,732 צמתים והטוהר הממוצע המשוקלל הוא 0.830. ההרכב אינו אחיד: חלק מן הקהילות נשלטות על ידי תחום אחד ואחרות מעורבות. המבנה תומך בקשר בין קהילה לתחום, אך אינו מאפשר לזהות תחום באופן דטרמיניסטי.

7. RQ1 - סיווג תחום מתוך מבנה הרשת

הניסוי משווה קו בסיס ללא מבנה, רוב שכנים, פיצ'רים מבניים ומודל המוסיף מידע קהילתי.



איור 5. ביצועי ארבעת מודלי הסיווג המבניים על פני חמש חלוקות; פסי השגיאה מייצגים סטיית תקן.

מודל	Macro F1	סטיית תקן	ROC-AUC	סטיית תקן
Majority Baseline	0.426	0.000	0.500	0.000
Neighbor Majority	0.702	0.006	0.785	0.005
Graph Features Only	0.751	0.005	0.841	0.004
Graph + Community Features	0.772	0.004	0.869	0.005

כל תוספת מידע משפרת את התוצאה: רוב השכנים חזק מקו הבסיס; מאפייני מרכזיות ומבנה חזקים יותר; והוספת מידע קהילתי מעלה את ה־AUC מ־0.841 ל־0.869. השיפור עקבי על פני החלוקות, וסטיות התקן קטנות.



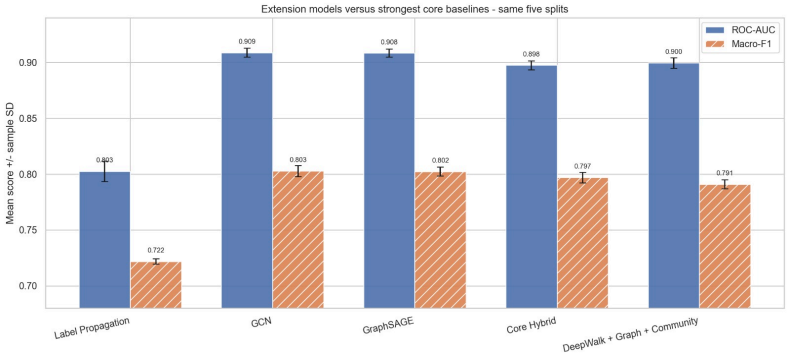
איור 6. השפעת כיול הסף שנבחר על validation בלבד: עלייה ב־Precision מול ירידה מתונה ב־Recall.

הסף שנבחר על validation היה 0.550 בממוצע. הוא העלה את Precision מ־0.622 ל־0.646 והוריד את Recall מ־0.721 ל־0.696. זהו trade-off תפעולי, לא שיפור מוחלט בכל המדדים.

תשובה ל־RQ1: כן, בתוך פרוטוקול transductive מבנה הרשת מספק אות חיזוי ברור מעל קווי הבסיס, ומידע קהילתי מוסיף ערך מעבר לשכנות ולמרכזיות.

8. RQ2 - רשת, תוכן וייצוגים נלמדים

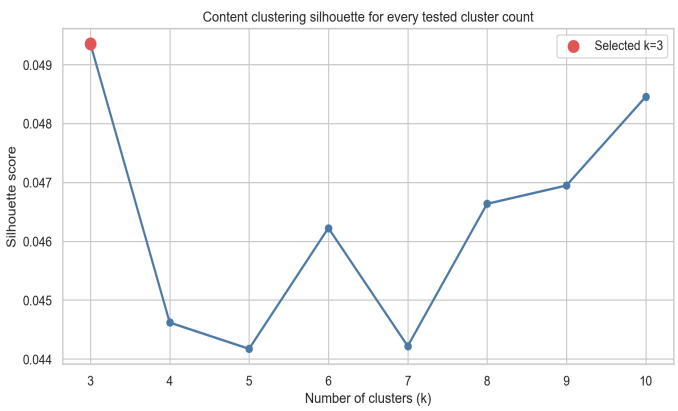
כאן נבדקת התרומה היחסית של רשת, תוכן, DeepWalk ו־Node2Vec תחת אותן חלוקות ואותו מסווג.

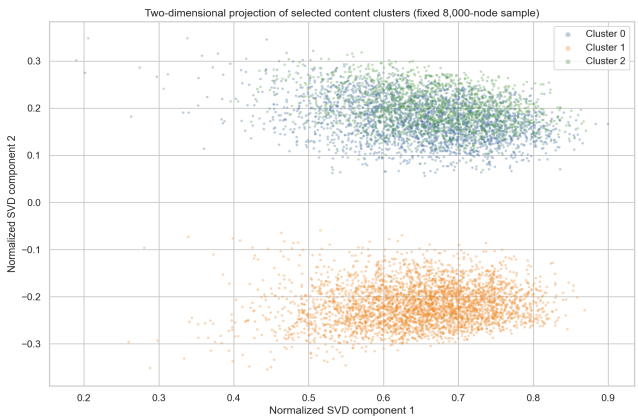


איור 7. השוואת מודלי ההרחבה למודלי הליבה החזקים על אותן חמש חלוקות.
העמודות מציגות ממוצע ROC-AUC ו־Macro-F1, ופסי השגיאה מציגים סטיית תקן בין החלוקות. GCN ו־GraphSAGE משיגים את הממוצעים הגבוהים ביותר, אך השיפור ביחס למודל הליבה הטוב ביותר קטן. ציר ה־Y מוצג בטווח מקוצר כדי להבליט את ההבדלים בין המודלים.

ייצוג / מקור מידע	Macro F1	ROC-AUC	סטיית תקן AUC
Graph + Community	0.772	0.869	0.005
Content-only	0.790	0.889	0.004
Hybrid Network + Content	0.797	0.898	0.004
DeepWalk	0.783	0.891	0.004
Node2Vec	0.783	0.890	0.005
DeepWalk + Graph + Community	0.791	0.900	0.005
Node2Vec + Graph + Community	0.791	0.899	0.005

מאפייני התוכן לבדם חזקים ממאפייני הרשת הידניים, עם ROC-AUC של 0.889 לעומת 0.869. עם זאת, הרשת מספקת מידע משלים: שילוב רשת ותוכן משפר את התוצאה ל־0.898. DeepWalk ו־Node2Vec מגיעים לביצועים דומים של כ־0.89 כאשר הם נבחנים לבדם. המודל החזק ביותר במחקר הליבה הוא DeepWalk + Graph + Community, עם ROC-AUC ממוצע של 0.900. ההבדלים בין המודלים המובילים קטנים, אך הם עקביים על פני חמש החלוקות.





איור 8. בחינת אשכולות תוכן ללא שימוש בתוויות התחום. משמאל: ערך Silhouette עבור k=3..10, כאשר הערך הגבוה ביותר מתקבל ב־k=3. מימין: הקרנה דו־ממדית של שלושת האשכולות שנבחרו על מדגם קבוע של 8,000 צמתים. ההפרדה החזותית חלקית בלבד ותואמת לערך ה־Silhouette הנמוך.

הבחירה ללא תוויות הובילה לשלושה אשכולות בגודל 13,366, 17,128 ו־7,206 מפתחים. ערך ה־Silhouette היה 0.0494 בלבד, ולכן ההפרדה בין הקבוצות חלשה. מצד שני, החלוקה הייתה יציבה לחלוטין בין חמש הרצות K-means, עם Adjusted Rand Index ממוצע של 1.000. ההתאמה לתוויות Web/Machine Learning הייתה נמוכה מאוד (NMI=0.0069, ARI=0.0181), וכך גם ההתאמה לקהילות Louvain (NMI=0.0079, ARI=0.0019). לכן ניתן לתאר את האשכולות כחלוקות גאומטריות יציבות של מאפייני התוכן, אך אין בסיס לקרוא להם תחי־תחומים מקצועיים או להעניק להם שמות סמנטיים.
הדמיון בביצועים אינו אומר שתוכן ומבנה שקולים. הם יכולים לקודד אותות שונים שמובילים ליכולת חיזוי דומה. השיפור במודלים המשולבים מעיד על חפיפה חלקית לצד מידע משלים.
תשובה ל־RQ2: מאפייני התוכן חזקים ממאפייני הרשת הידניים, אך ההטמעות המבניות מצמצמות את הפער. השילובים בין מקורות המידע משיגים את התוצאות הטובות ביותר במחקר הליבה, ולכן המסקנה היא שהתוכן ומבנה הרשת מספקים מידע חופף בחלקו אך גם מידע משלים.

8.1 הרחבת המחקר – Label Propagation, GCN, GraphSAGE ואשכולות תוכן

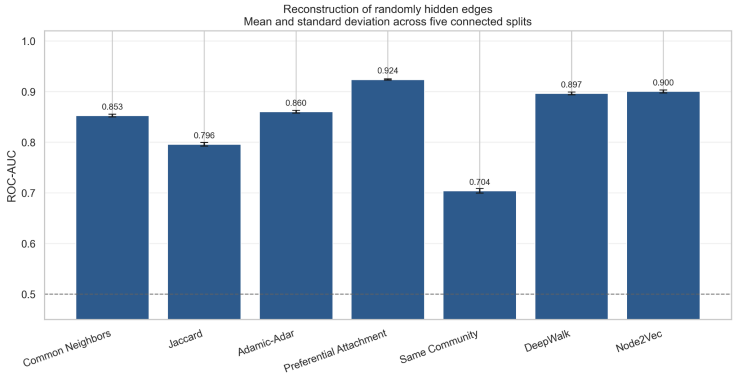
ההרחבה בוחנת אם שיטות נוספות מסוגלות לחלץ מידע שאינו נלכד במלואו על ידי מאפייני הגרף הידניים, DeepWalk ו־Node2Vec. כל שלושת מודלי הסיווג נבדקו על אותן חמש חלוקות של המחקר המרכזי. במדדי Precision, Recall ו־F1, Machine Learning מוגדרת כמחלקה החיובית; Macro-F1 נותן משקל שווה לשתי המחלקות.

מודל	Macro-F1	ROC-AUC	מסקנה
Label Propagation	0.7218 ± 0.0024	0.8025 ± 0.0092	קו בסיס פשוט ושמרני המבוסס על שכנים
GCN	0.8028 ± 0.0049	0.9087 ± 0.0040	התוצאה הטובה ביותר בהרחבה
GraphSAGE	0.8024 ± 0.0040	0.9083 ± 0.0036	ביצועים כמעט זהים ל־GCN

GCN ו־GraphSAGE עברו את מודל הליבה החזק בכל חמש החלוקות גם ב־ROC-AUC וגם ב־Macro-F1. עם זאת, השיפור קטן: מודל הליבה הטוב הגיע לכ־0.900, לעומת 0.9087 עבור GCN ו־0.9083 עבור GraphSAGE. לכן המסקנה היא ש־Message Passing לוכד מידע מבני נוסף, אך אינו משנה באופן מהותי את תמונת המחקר המרכזית.
Label Propagation היה חלש יותר, עם Precision של 0.8498 אך Recall של 0.4065. פירוש הדבר הוא שהמודל שמרני: כאשר הוא מזהה מפתח Machine Learning הוא בדרך כלל צודק, אך הוא מחמיץ מפתחים רבים מהמחלקה. התוצאה מראה שהפצת תוויות מקומית והומופיליה לבדן אינן מספיקות, ושנדרש ייצוג מבני עשיר יותר.
מסקנת ההרחבה: Label Propagation מראה שהומופיליה מקומית מספקת אות חיזוי, אך אינה מספיקה לביצועים גבוהים. GCN ו־GraphSAGE מוסיפים Message Passing נלמד ומשיגים שיפור קטן אך עקבי על פני מודלי הליבה, ולכן קיימים בגרף דפוסים מקומיים ורב־שלביים שהייצוגים הקודמים אינם לוכדים במלואם. אשכולות התוכן יציבים אך אינם מופרדים היטב ואינם תואמים לתוויות התחום או לקהילות הרשת. ההרחבה מעמיקה את הממצאים המקוריים, אך אינה מצדיקה טענות על סיבתיות, תחזית עתידית או ביצועים על צמתים חדשים.

9. RQ3 - שחזור קשתות שהוסתרו

הערכה תקינה של שחזור קשתות דורשת להסתיר קשתות בלי לפרק את הרשת. לכן בכל seed נשמר יער פורש מלא, והקשתות החיוביות נלקחות רק מן הקשתות שאינן בעץ. בדיקות הדיאגנוסטיקה מאשרות שבכל חמש החלוקות יש רכיב קשיר אחד, אין צמתים מבודדים ואין חפיפה בין positive לבין negative.

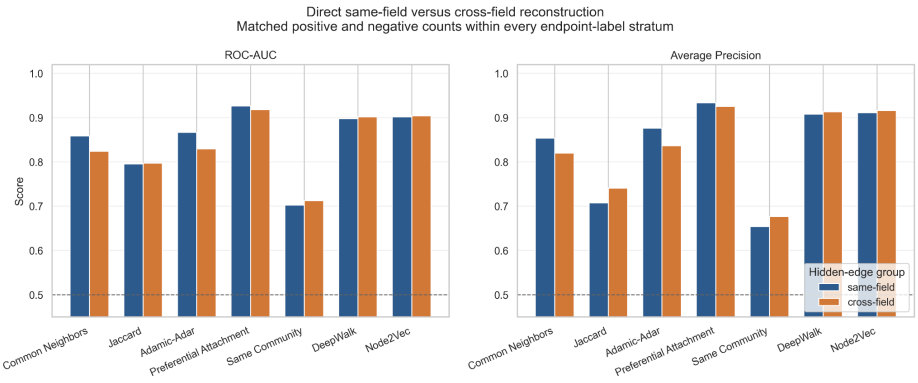


איור 9. ביצועי שיטות שחזור הקשתות על קשתות חיוביות שהוסתרו, מול מספר זהה של non-edges, בממוצע על פני חמש חלוקות קשירות.

שיטה	ROC-AUC	סטיית תקן	Average Precision	סטיית תקן
Preferential Attachment	0.924	0.001	0.931	0.001
Node2Vec	0.900	0.003	0.911	0.002
DeepWalk	0.897	0.003	0.907	0.002
Adamic–Adar	0.860	0.003	0.870	0.002
Common Neighbors	0.853	0.003	0.848	0.003

0.006	0.713	0.004	0.796	Jaccard
0.004	0.657	0.004	0.704	Same Community

Preferential Attachment מוביל בפער עם 0.924 AUC ו־0.931 AP. התוצאה מתאימה למבנה כבד־הזנב ולחשיבות הדרגות, אך אינה מוכיחה שזהו מנגנון יצירת הקשר. DeepWalk ו־Node2Vec מגיעים לכ־0.90 ומראים שהטמעות מסכמות מידע שימושי גם למשימת קשתות.



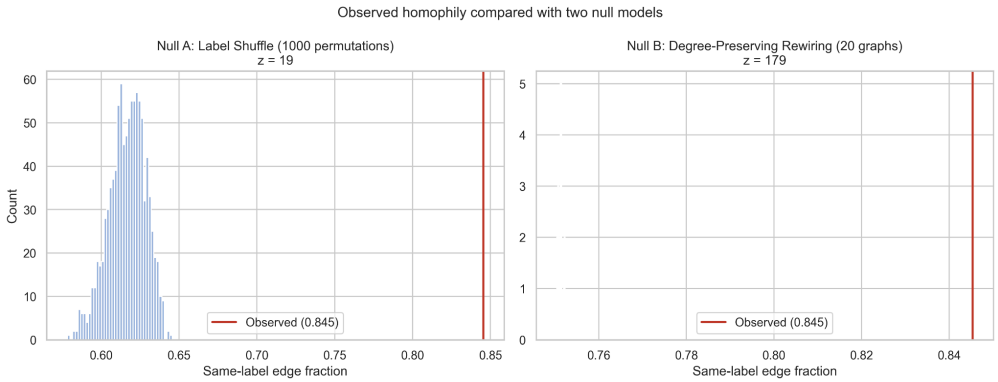
איור 10. השוואת ביצועי שחזור של קשתות תוך־תחומיות וקשתות בין־תחומיות בכל שבע השיטות, תחת דגימה מאוזנת לפי סוג הקשת.

ב־Preferential Attachment, קשתות same-field הגיעו ל־0.926 AUC ול־0.933 AP, לעומת 0.918 AUC ו־0.925 AP בקשתות cross-field. פער ה־AUC הוא 0.008 בלבד: עקבי, אך קטן. לכן המסקנה היא שקשתות תוך־תחומיות מעט קלות יותר לשחזור בפרוטוקול זה.

תשובה ל־RQ3: ניתן לשחזר חלק ניכר מהקשתות שהוסתרו תוך שמירת קשירות הגרף. Preferential Attachment הוא המדד החזק ביותר, עם ROC-AUC של 0.924. לקשתות תוך־תחומיות קיים יתרון קטן בלבד בשחזור, ולכן אין לפרש את הפער כהוכחה למנגנון חברתי או כתחזית של קשרים עתידיים.

10. RQ4 - הומופיליה, מודלי אפס ומודלי רשת

84.53% מן הקשתות מחברות מפתחים מאותו תחום. כדי לברר אם הערך נובע רק מהתפלגות התוויות או מרצף הדרגות, הושוותה הרשת לשני מודלי אפס: 1,000 ערבובי תוויות על גרף קבוע ו־20 גרפים משמרי־דרגות.



איור 11. הומופיליה נצפית מול ערבובי תוויות ומול גרפים משמרי־דרגות. הקו הנצפה גבוה משתי התפלגויות האפס.

מודל אפס	נצפה	ממוצע אפס	סטיית תקן	z	p אמפירי
ערבוב תוויות	0.845344	0.616599	0.011765	19.44	0.000999
גרף משמר־דרגות	0.845344	0.751256	0.000525	179.08	0.047619

ערבוב התוויות מראה שהתפלגות המחלקות לבדה אינה מסבירה את ההומופיליה הנצפית. הגרפים משמרי־הדרגות הגיעו להומופיליה ממוצעת של 0.751, ולכן רצף הדרגות מסביר חלק מן התופעה, אך לא את הפער כולו עד לערך הנצפה של 0.845. הערך הנצפה היה גבוה מכל 20 הגרפים המשמרים שנבדקו. עם זאת, מספר הדגימות מגביל את רזולוציית המבחן: ערך ה־p האמפירי הנמוך ביותר

האפשרי הוא 1/21=0.047619. גם המודולריות גבוהה ביחס לגרפים המשמרים: 0.453 ברשת הנצפית לעומת ממוצע של 0.189, עם אותו ערך p אמפירי. התוצאות מספקות עדות לכך שהמבנה אינו מוסבר במלואו באמצעות התפלגות התוויות או רצף הדרגות, אך אינן מצדיקות טענה על מובהקות חזקה יותר מזו שמאפשר מספר הדגימות.

10.1 השוואה למודלי רשת

הרשת הנצפית ומודלי ייחוס מרכזיים

רשת	קשתות	Clustering	מרחק ממוצע	דרגת שיא
GitHub observed	289,003	0.1675	3.218	9,458
Erdős–Rényi	289,003	0.0004	4.125	34
Barabási–Albert (m=8)	301,536	0.0034	3.590	891

Small-World ומודל אפס משמר־דרגות

רשת	קשתות	Clustering	מרחק ממוצע	דרגת שיא
Watts–Strogatz (k=16, p=0.1)	301,600	0.5117	5.552	22
Degree-preserving null	289,003	0.0914	3.156	9,458

מודל Erdős–Rényi משחזר את מספר הקשתות, אך אינו משחזר את רמת ההתקבצות או את דרגת השיא. מודל Barabási–Albert יוצר התפלגות כבדת־זנב, אך ריכוז הקשרים בו עדיין נמוך משמעותית מזה שנצפה ברשת GitHub. מודל Watts–Strogatz מייצר התקבצות גבוהה ומרחקים קצרים, אך אינו משחזר את התפלגות הדרגות. הגרף משמר־הדרגות שומר בדיוק על רצף הדרגות ומתקרב למרחק הממוצע של הרשת הנצפית, אך אינו משחזר במלואו את ההתקבצות, ההומופיליה או המודולריות. מודלי Barabási–Albert ו־Watts–Strogatz משמשים להשוואה מבנית איכותנית ואינם מותאמים בדיוק למספר הקשתות של הרשת המקורית.

תשובה ל־RQ4: ההומופיליה והמודולריות ברשת הנצפית גבוהות מהערכים שהתקבלו במודלי האפס שנבדקו. רצף הדרגות מסביר חלק מן ההומופיליה, אך אינו מסביר אותה במלואה ואינו משחזר לבדו את מבנה הקהילות. גם מודלי הרשת הקלאסיים משחזרים מאפיינים מסוימים בלבד, ולא מודל יחיד מצליח לשחזר את כל מאפייני רשת GitHub.

11. דיון משולב, מגבלות ומסקנות

11.1 דיון משולב

ארבע שאלות המחקר מציגות תמונה עקבית. מאפייני שכנות, מרכזיות וקהילה נושאים מידע משמעותי על תחום ההתמחות של המפתחים. מאפייני התוכן מספקים אות חיזוי חזק, אך שילובם עם מידע מבני משפר את הביצועים ומראה ששני המקורות משלימים זה את זה. הצלחת Preferential Attachment מתיישבת עם ריכוז הקשרים סביב צמתים בעלי דרגה גבוהה, ואילו Louvain וההומופיליה מצביעים על ארגון קהילתי הקשור לתחומי ההתמחות. מודלי האפס מראים שהתוצאות אינן מוסברות רק באמצעות חוסר האיזון בין התוויות או רצף הדרגות.

Label Propagation אינו מגיע לביצועי מודלי הליבה, ולכן הקשר בין תחום מקצועי למבנה הרשת אינו מוסבר רק באמצעות התוויות של השכנים הישירים. לעומת זאת, GCN ו־GraphSAGE משיגים שיפור קטן ועקבי ומראים שצבירה נלמדת של מידע מהשכנים יכולה לחלץ אות נוסף מן המבנה. ניסוי אשכולות התוכן מראה שהתוכן והרשת אינם יוצרים בהכרח אותה חלוקה: האשכולות יציבים אך כמעט אינם חופפים לתוויות התחום או לקהילות Louvain.

11.2 מגבלות

- **הנתונים הם תמונת מצב מיוני 2019 ואינם מייצגים בהכרח את GitHub כיום.**
- **תוויית היעד בינארית ומצמצמת קשת רחבה של תחומי פיתוח לשתי קבוצות בלבד.**
- **התוויות ומאפייני התוכן נגזרו ממידע פרופיל, ולכן ייתכנו רעש, חוסר או חוסר עדכניות.**
- **כל ניסויי הסיווג, לרבות GCN ו־GraphSAGE, בוצעו בתרחיש transductive. לא נבדקה הכללה לצמתים חדשים או לרשת עתידית, ולכן אין להסיק ביצועים inductive.**
- **Betweenness חושב בקירוב, והטמעות DeepWalk ו־Node2Vec נבדקו בתקציב פרמטרים קבוע וללא חיפוש היפר־פרמטרים רחב.**
- **חיפוש ההיפר־פרמטרים של מודלי ה־GNN היה מצומצם בשל זמן החישוב. בשתי חלוקות של GCN, ה־epoch שנבחר הגיע לתקרת 200 epochs, ולכן לא נבדקה אפשרות להתכנסות מאוחרת יותר.**
- **שחזור קשתות שהוסתרו אינו תחזית של קשתות עתידיות ואינו כולל כיוון או סדר זמנים.**

- דגימת non-edges אקראית עשויה להקל על שיטות המבוססות על דרגת הצמתים, ובעיקר על Preferential Attachment. ניסוי מחמיר יותר יכול להשתמש בזוגות שליליים מותאמי־דרגה או בזוגות הנמצאים במרחק שניים בגרף.
- הפער בין קשתות same-field לקשתות cross-field קטן ותלוי בשיטת הדגימה ובשיטת השחזור, ולכן אין לפרשו כממצא סיבתי או כמסקנה כללית על היווצרות קשרים.
- מודלי האפס מבודדים מאפיינים מסוימים, אך אינם תיאור מלא של התהליך החברתי או המקצועי. ההשוואה לגרפים משמרי־דרגות מבוססת על 20 דגימות בלבד, ולכן רזולוציית ערך ה־p האמפירי מוגבלת ל־1/21.
- תוצאות ההרחבה מבוססות על חמש חלוקות ועל תמונת מצב סטטית אחת של הרשת. נדרשים מאגרים וזמנים נוספים כדי לבדוק הכללה רחבה יותר.
- אשכולות התוכן נבנו לאחר צמצום ל־64 רכיבי SVD, ששמרו 55.9% מן השונות. ערך ה־Silhouette הנמוך והיעדר פירוש אנושי ישיר למאפיינים אינם מאפשרים להסיק שמדובר בתתי־תחומים מקצועיים אמיתיים.

11.3 מסקנות

RQ1: מבנה הרשת מאפשר לסווג את תחום ההתמחות בצורה טובה יותר מקווי הבסיס. מאפייני גרף וקהילה הגיעו ל־ROC-AUC ממוצע של 0.869.

RQ2: מאפייני התוכן היו חזקים ממאפייני הרשת הידניים, אך שילוב מקורות המידע שיפר את התוצאה. המודל הטוב ביותר במחקר הליבה, DeepWalk + Graph + Community, הגיע ל־ROC-AUC ממוצע של 0.900.

RQ3: ניתן לשחזר חלק ניכר מהקשתות שהוסתרו תוך שמירת קשירות הגרף. Preferential Attachment היה המדד החזק ביותר, עם ROC-AUC ממוצע של 0.924. היתרון בשחזור קשתות תוך־תחומיות היה קטן ולכן יש לפרשו בזהירות.

RQ4: ההומופיליה והמודולריות שנצפו היו גבוהות מהערכים שהתקבלו במודלי האפס שנבדקו. רצף הדרגות מסביר חלק ממבנה הרשת, אך אינו מסביר לבדו את ההומופיליה ואת הקהילתיות.

Extensions: Label Propagation הגיע ל־ROC-AUC של 0.8025 והראה שהומופיליה מקומית לבדה אינה מספיקה. GCN הגיע ל־0.9087 ו־GraphSAGE ל־0.9083, ושניהם שיפרו באופן קטן אך עקבי את המודל הטוב ביותר במחקר המרכזי. התוצאה מצביעה על כך ש־Message Passing לוכד מידע מבני נוסף מעבר למרכזיות, קהילות והטמעות המבוססות על הילוכים אקראיים. אשכולות התוכן היו יציבים בין ההרצות אך בעלי הפרדה חלשה והתאמה נמוכה לתוויות ולקהילות, ולכן הם אינם תומכים בהגדרה של תתי־תחומים מקצועיים ברורים.

בסיכום, הפרויקט מציג מסגרת ניסויית אחידה ושחזורית המשלבת ניתוח מבני, מרכזיות, קהילות, סיווג, הטמעות גרף, שחזור קשתות, מודלי אפס, Message Passing ואשכולות תוכן. הממצאים מצביעים על קשר חיזויי ברור בין תחום ההתמחות לבין מבנה רשת GitHub, אך אינם מוכיחים קשר סיבתי.

11.4 שחזור והרצה

הפרויקט כולל תשעה Jupyter Notebooks מסודרים, 01–09. 01–08 Notebooks מכילים את מחקר הליבה, ו־09 Notebook מריץ בנפרד את מחקר ההרחבה: Label Propagation, GCN, GraphSAGE ואשכולות תוכן. כל תשעת ה־Notebooks הורצו מחדש מ־Kernels נקיים ובסדר המלא ללא שגיאות. הנתונים נקראים ישירות מתיקיית data, והתוצרים של מחקר הליבה נשמרים תחת outputs/tables ו־outputs/figures.

כל ההרחבות מופעלות מחדש מקוד המקור ואינן מסתמכות על תחזיות שמורות. 09 Notebook כולל 17 תאי קוד בעלי מספרי הרצה רציפים, 14 תרשימים מוטמעים וללא פלטי שגיאה. בדיקות דליפת המידע אישרו שבכל חמש החלוקות לא נחשפו תוויות test בזמן בחירת ההגדרות או בזמן האימון הסופי. טבלאות ההרחבה נשמרות תחת outputs/extensions/tables והתרשימים תחת outputs/extensions/figures. הוראות ההתקנה, מבנה הפרויקט וסדר ההרצה מפורטים בקובץ README.md.

מקורות

1. Rozemberczki, B., Allen, C., & Sarkar, R. (2019). Multi-scale Attributed Node Embedding.
2. Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks.
3. Perozzi, B., Al-Rfou, R., & Skiena, S. (2014). DeepWalk: Online Learning of Social Representations.
4. Grover, A., & Leskovec, J. (2016). node2vec: Scalable Feature Learning for Networks.
5. Liben-Nowell, D., & Kleinberg, J. (2003). The Link Prediction Problem for Social Networks.
6. Clauset, A., Shalizi, C. R., & Newman, M. E. J. (2009). Power-law distributions in empirical data.
7. Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). The PageRank Citation Ranking.
8. Erdős, P., & Rényi, A. (1959). On Random Graphs.
9. Barabási, A.-L., & Albert, R. (1999). Emergence of Scaling in Random Networks.
10. Watts, D. J., & Strogatz, S. H. (1998). Collective dynamics of small-world networks.
11. Zhu, X., & Ghahramani, Z. (2002). Learning from Labeled and Unlabeled Data with Label Propagation.
12. Kipf, T. N., & Welling, M. (2017). Semi-Supervised Classification with Graph Convolutional Networks.
13. Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Inductive Representation Learning on Large Graphs.

14. Halko, N., Martinsson, P. G., & Tropp, J. A. (2011). Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions.
15. Lloyd, S. (1982). Least Squares Quantization in PCM.
16. חומרי הקורס באלגוריתמים בגרפים: יסודות גרפים, מדדי מרכזיות, ניתוח קהילות, מודלי רשת, שחזור קשתות, הטמעות וניתוח גרפים